ŽILINSKÁ UNIVERZITA V ŽILINE
Fakulta riadenia
a informatiky

BAKALÁRSKA PRÁCA

HODNOTENIE SPOĽAHLIVOSTI PREDIKCIE S VYUŽITÍM VÁHOVÉHO FUZZY PRÍSTUPU

Anatolii Lopatiuk

Študijný program: Informatika

Študijný odbor: Informatika

Školiace pracovisko: Žilinská univerzita v Žiline, Katedra informatiky

Vedúci bakalárskej práce: prof. Ing. Vitaly Levashenko, PhD.

Žilina 2025

ŽILINSKÁ UNIVERZITA V ŽILINE, FAKULTA RIADENIA A INFORMATIKY.

ZADANIE TÉMY BAKALÁRSKEJ PRÁCE.

Študijný program: Informatika

Meno a priezvisko	**Osobné číslo**
Anatolii Lopatiuk	561391

Názov práce v slovenskom aj anglickom jazyku

Implementácia algoritmov analýzu spoľahlivosti databáz

Implementation of algorithms for analysis of databases reliability

Zadanie úlohy, ciele, pokyny pre vypracovanie (Ak je málo miesta, použite opačnú stranu)

Cieľ bakalárskej práce:
Cieľom prace je prieskum a implementácia algoritmov analýzu správnosti údajov v databázach .

Obsah:
1. Oboznámenie sa s existujúcimi riešeniami.
2. Rozbor existujúcich algoritmov analýzu spoľahlivosti.
3. Príprava softvérového nástroja pre realizáciu algoritmov v C++.
4. Experimenty a porovnanie algoritmov na rôznych výstupných dátach.

Meno a pracovisko vedúceho BP: prof. Ing. Vitaly Levashenko, PhD., KI, ŽU
Meno a pracovisko tutora BP:

garant štud. programu
(dátum a podpis)

Zadanie zaregistrované dňa 31. 10. 2024 pod číslom 3323/2024 podpis

Čestné vyhlásenie

Vyhlasujem, že som zadanú bakalársku prácu vypracoval samostatne, pod odborným vedením vedúceho práce/školiteľa a používal som len literatúru uvedenú v práci.

Žilina 22. apríla 2025

podpis

Poďakovanie

Rád by som vyjadril úprimné poďakovanie svojmu vedúcemu bakalárskej práce, prof. Ing. Vitalymu Levashenkovi, PhD., za odborné vedenie, cenné rady, trpezlivosť a podporu, ktoré mi poskytoval počas celého môjho štúdia. Jeho odborný prístup a cenné usmernenia boli pre mňa veľkou oporou nielen pri písaní tejto práce, ale aj počas môjho odborného rastu.

Taktiež by som sa chcel srdečne poďakovať svojej rodine za ich neustálu podporu, pochopenie a povzbudenie počas celého štúdia, ktoré mi umožnili úspešne zvládnuť všetky výzvy akademického života.

Abstrakt

LOPATIUK, Anatolii: Hodnotenie spoľahlivosti predikcie v rozhodovacích modeloch s využitím váhového fuzzy prístupu. [Bakalárska práca]. Žilinská univerzita v Žiline. Fakulta riadenia a informatiky; Katedra informatiky. – Vedúci: prof. Ing. Vitaly Levashenko, PhD. – Stupeň odbornej kvalifikácie: Bakalár. – Žilina: FRI UNIZA, 2025.

Táto bakalárska práca sa zaoberá analýzou spoľahlivosti predikcií v rozhodovacích modeloch na báze váhového fuzzy prístupu. Cieľom práce je navrhnúť, implementovať a experimentálne overiť rozšírený model, ktorý dynamicky vyberá závislé páry atribútov pomocou miery vzájomnej informácie, automaticky optimalizuje hyperparametre a využíva rôzne režimy hodnotenia spoľahlivosti, vrátane režimu batched-end reliability.

Teoretická časť práce obsahuje rozbor pôvodného váhového fuzzy modelu podľa Maimona a jeho rozšírenie o nové mechanizmy na zvýšenie presnosti a adaptability. Praktická časť zahŕňa implementáciu riešenia v prostredí C++, experimentálne testovanie na verejných datasetoch Car Evaluation a Balance Scale získaných z UCI Machine Learning Repository, a analýzu dosiahnutých výsledkov z hľadiska presnosti klasifikácie a fuzzy miery spoľahlivosti rozhodnutí.

Výsledky experimentov potvrdzujú, že navrhnutý prístup dosahuje vyššiu presnosť a lepšiu schopnosť identifikovať neisté rozhodnutia v porovnaní s pôvodným modelom. Tým práca prispieva k rozvoju metodík hodnotenia kvality predikcie v systémoch pracujúcich s neurčitosťou.

Kľúčové slová: váhový fuzzy model, spoľahlivosť predikcie, fuzzy reliability, váhové príspevky, interpolácia pravdepodobností.

Abstract

LOPATIUK, Anatolii: Reliability Assessment of Predictions in Decision Models Using a Weighted Fuzzy Approach. [Bachelor's thesis]. University of Žilina. Faculty of Management Science and Informatics; Department of Informatics. – Supervisor: prof. Ing. Vitaly Levashenko, PhD. – Degree of academic qualification: Bachelor. – Žilina: FRI UNIZA, 2025.

This bachelor's thesis deals with the analysis of prediction reliability in decision-making models based on a weighted fuzzy approach. The aim of the work is to design, implement, and experimentally verify an enhanced model that dynamically selects dependent attribute pairs using mutual information, automatically optimizes hyperparameters, and applies different reliability evaluation modes, including the batched-end reliability mode.

The theoretical part of the thesis provides an analysis of the original weighted fuzzy model proposed by Maimon and its extension with new mechanisms aimed at improving prediction accuracy and adaptability. The practical part covers the implementation of the solution in C++, experimental testing on public datasets Car Evaluation and Balance Scale obtained from the UCI Machine Learning Repository, and the analysis of achieved results regarding classification accuracy and fuzzy reliability of decisions.

The experimental results confirm that the proposed approach achieves higher accuracy and better capability to identify uncertain decisions compared to the original model. Thus, the thesis contributes to the advancement of methods for evaluating the quality of predictions in systems working with uncertainty.

Keywords: weighted fuzzy model, prediction reliability, fuzzy reliability, weighted contributions, probability interpolation.

Obsah

Úvod 11

1 Teoretické základy analýzy spoľahlivosti dát 12

1.1 Spoľahlivosť údajov ako predmet analýzy. **Chyba! Záložka nie je definovaná.**

1.1.1 Prístupy k zabezpečeniu kvality a spoľahlivosti údajov 13

1.1.2 Pojem „Zero Defect Data“ a jeho limity v praxi 13

1.2 Neurčitá logika a teória fuzzy množín ..... **Chyba! Záložka nie je definovaná.**

1.2.1 Lingvistické premenné 14

1.2.2 Základy fuzzy logiky a množín 14

1.3 Informačné miery a pravdepodobnostné modely 15

1.3.1 Entropia a informačný zisk 15

1.3.2 Fuzzy entropia 16

1.3.3 Váhové pravdepodobnostné modely 17

1.3.4 Základné pravdepodobnostné distribúcie v rozhodovacích modeloch 18

2 Analýza existujúcich prístupov a výber metódy 20

2.1 Prístup založený na váhovom fuzzy modeli 20

2.1.1 Koncepcia a hlavné charakteristiky modelu v práci Maimon et al. 20

2.1.1.1 Cieľ a motivácia modelu 20

2.1.1.2 Interpolácia pravdepodobností v klasifikácii údajov 20

2.1.1.3 Jednoduché váhové príspevky atribútov 27

2.1.1.4 Párové váhy atribútov 28

2.1.1.5 Spoľahlivosť rozhodnutia 30

2.1.1.6 Postup výpočtu vo váhovom fuzzy modeli 32

2.1.2 Rozšírenia váhového fuzzy modelu pre zvýšenie presnosti a robustnosti 33

2.1.2.1 Dynamický výber závislých párov atribútov na základe miery vzájomnej informácie 34

2.1.2.2 Automatická optimalizácia hyperparametrov pomocou krížovej validácie 36

2.1.2.3 Hodnotenie spoľahlivosti pomocou viacerých režimov 38

2.2 Záver 39

3 Teoretické základy analýzy spoľahlivosti dát 41

3.1 Návrh a architektúra riešenia 41

3.2 Hlavné komponenty systému 41

3.2.1 FuzzyReliabilityModel 42

3.2.2 FuzzyReliabilityModel 44
3.2.3 OutputCSV 45
3.2.4 Config 47
3.2.5 Riadiaci tok systému WaFRE 48
3.3 Používateľské rozhranie a výstupy systému 49
3.3.1 Konzolový výstup 50
3.3.2 Exportované CSV výstupy 51
3.4 Záver 56
4 Experimentálna analýza a výsledky 57
4.1 Cieľ a metodológia experimentov 57
4.2 Opis použitých datasetov 58
4.2.1 Car Evaluation dataset 58
4.2.1.1 Parametre a charakteristika datasetu Car Evaluation 58
4.2.1.2 Porovnanie výkonnosti modelov 59
4.2.1.3 Vplyv operácie shuffle na presnosť a spoľahlivosť v režime retrained 59
4.2.1.4 Analýza príkladov s nízkou mierou spoľahlivosti 61
4.2.2 Balance Scale dataset 62
4.2.2.1 Parametre a charakteristika Balance Scale 62
4.2.2.2 Porovnanie výkonnosti modelov 63
4.2.2.3 Vplyv operácie shuffle na presnosť a spoľahlivosť v režime retrained 64
4.2.2.4 Analýza príkladov s nízkou mierou spoľahlivosti 65
4.3 Záver 67

Zoznam obrázkov

Obrázok 1 Funkcia príslušnosti pre kategórie spokojnosti zákazníka 15
Obrázok 2 Procesný cyklus fuzzy klasifikátora – od dát k spoľahlivej predik 33
Obrázok 3 Porovnanie stratégií tréningu a inferencie pri hodnotení spoľahlivosti: baseline, retrained a batched-end 38
Obrázok 4 Štruktúra triedy FuzzyReliabilityModel v systéme WaFRE 43
Obrázok 5 Modul ReliabilityUtils a režimy výpočtu fuzzy spoľahlivosti 45
Obrázok 6 Modul OutputCSV a štruktúra výstupných analytických údajov 46
Obrázok 7 Diagram aktivity hodnotenia fuzzy modelu spoľahlivosti údajov 49
Obrázok 8 Konzolový výstup WaFRE.....51
Obrázok 9 Porovnanie presnosti pôvodného a navrhnutého modelu pred a po shuffle60
Obrázok 10 Zmena priemernej fuzzy spoľahlivosti modelov po shuffle operácii 60
Obrázok 11 Porovnanie presnosti pôvodného a navrhnutého modelu pred a po shuffle dataset Balance Scale.....64
Obrázok 12 Zmena priemernej fuzzy spoľahlivosti modelov po shuffle operácii dataset Balance Scale 65

Zoznam tabuliek

Tabuľka 1 Typológia chýb ovplyvňujúcich spoľahlivosť údajov 12
Tabuľka 2 Tradičné prístupy k zabezpečeniu kvality údajov 13
Tabuľka 3 Východiskový minidataset pre demonstráciu modelu.....23
Tabuľka 4 Marginálne frekvencie cieľovej premennej V.....24
Tabuľka 5 Podmienené frekvencie tried V pre hodnotu T = „stredný“ 24
Tabuľka 6 Podmienené frekvencie tried V pre hodnotu *Q* = „stredná“ 24
Tabuľka 7 Vyhladené podmienené pravdepodobnosti pre hodnotu Q = „stredná“(β=0,6) 26
Tabuľka 8 Nezávislý odhad párovej pravdepodobnosti pre kombináciu T = „stredný“ a Q = „stredná“.....26
Tabuľka 9 Interpolovaná párová pravdepodobnosť pre dvojicu T = „stredný“ a Q=„stredná“.....27
Tabuľka 10 Vstupné pravdepodobnosti, ktoré slúžia ako podklad pre výpočet párovej váhy 29
Tabuľka 11 Relatívne pomery pravdepodobností pre kombináciu T (stredný) × Q (stredná).....29
Tabuľka 12 Logaritmy relatívnych pomerov pre T = stredný a Q = stredná.....29
Tabuľka 13 Výpočet párovej váhy pre kombináciu T = stredný a Q = stredná 30
Tabuľka 14 Marginálne rozdelenia T, Q, P a C po aktualizácii vzorky 34
Tabuľka 15 Spoločné a marginálne rozdelenia hodnôt T a Q 35
Tabuľka 16 Výsledky testu informatívnosti (MI) 36
Tabuľka 17 Porovnanie fixných a automaticky optimalizovaných hyperparametrov.....37
Tabuľka 18 Porovnanie režimov hodnotenia spoľahlivosti modelu 39
Tabuľka 19 Porovnanie pôvodného modelu a navrhnutého riešenia 40
Tabuľka 20 Zoznam najvýznamnejších jednoduchých váhových príspevkov.....52
Tabuľka 21 Najsilnejšie interakcie atribútových dvojíc podľa váhového príspevku.....52
Tabuľka 22 Porovnanie prípadov s nízkou spoľahlivosťou v rôznych režimoch učenia54
Tabuľka 23 Porovnanie spoľahlivosti predikcií v režimoch Base, Retrained a BatchedEnd 55
Tabuľka 24 Štruktúra vstupných a cieľových premenných v datasete Car Evaluation .58
Tabuľka 25 Diskrétne kódovanie hodnôt atribútov datasetu Car Evaluation 58
Tabuľka 26 Výkonnosť modelov vo všetkých režimoch učenia na datasete Car Evaluation 59
Tabuľka 27 Príklady s extrémne nízkou fuzzy spoľahlivosťou v hraničných prípadoch v datasete Car Evaluation 61

Tabuľka 28 Štruktúra vstupných a cieľových premenných v datasete Balance Scale ..62
Tabuľka 29 Diskrétne kódovanie hodnôt atribútov datasetu Balance Scale.....63
Tabuľka 30 Výkonnosť modelov vo všetkých režimoch učenia v datasete Balance Scale 63
Tabuľka 31 Príklady s extrémne nízkou fuzzy spoľahlivosťou v hraničných prípadoch v datasete Balance Scale.....66

Zoznam skratiek

Skratka	Anglický význam	Slovenský význam
MI	Mutual Information	vzájomná informácia
IG	Information Gain	informačný zisk
CV	Cross-Validation	krížová validácia
GUI	Graphical User Interface	grafické používateľské rozhranie
UCI	University of California, Irvine (Machine Learning Repository)	Repozitár strojového učenia Univerzity v Kalifornii v Irvine
WaFRE	Weighted Fuzzy Reliability Evaluation	váhové fuzzy hodnotenie spoľahlivosti
ID	Identifier	identifikátor
R	Reliability	fuzzy miera spoľahlivosti

Slovník pojmov

Pojem	Vysvetlenie
Batched-end režim	Režim hodnotenia spoľahlivosti, v ktorom je model trénovaný výhradne na poslednej časti (napr. 10 %) dátovej množiny, čím simuluje oneskorené učenie z najnovších prípadov.
Baseline spoľahlivosť	Základný režim výpočtu spoľahlivosti modelu, pri ktorom sa vyhodnocujú výsledky bez ďalšieho učenia na nových dátach.
Cross-validácia	Metóda validácie modelu založená na opakovanom rozdelení dát do trénovacích a testovacích častí s cieľom overiť generalizačnú schopnosť modelu.
Dátová množina	Súbor štruktúrovaných údajov používaný na učenie, testovanie alebo validáciu modelu (často označovaný ako *dataset*).
Gradual data trust	Princíp postupnej dôveryhodnosti — koncept, podľa ktorého sa dôvera v dáta buduje dynamicky na základe ich kvality a spracovania.
Grid search	Mriežkové vyhľadávanie — systematické skúšanie rôznych kombinácií hyperparametrov modelu s cieľom nájsť optimálnu konfiguráciu.
Retrained režim	Režim hodnotenia, pri ktorom je model opätovne natrénovaný na celej dátovej množine vrátane nových prípadov, čo umožňuje zohľadniť priebežné učenie.
Shuffle	Operácia náhodného usporiadania príkladov v dátovej množine pred učením, ktorá má za cieľ zabrániť pretrénovaniu a zlepšiť generalizáciu.
Spoľahlivosť dát	Miera dôvery v správnosť, úplnosť a konzistentnosť údajov, ktorá ovplyvňuje kvalitu rozhodnutí a predikcií modelu.
Zero defect data	Koncept nulovej chybovosti údajov — ideálny stav, v ktorom sú všetky dáta úplne správne, bez akýchkoľvek chýb alebo odchýlok.

ÚVOD

Spoľahlivosť vstupných údajov rozhodujúcim spôsobom ovplyvňuje presnosť analytických a klasifikačných systémov. Táto práca sa zameriava na rozšírenie váhového fuzzy modelu o mechanizmy, ktoré umožňujú priebežne vyhladzovať pravdepodobnostné odhady, automaticky vyberať informatívne dvojice atribútov podľa miery vzájomnej informácie a optimalizovať hyperparametre prostredníctvom krížovej validácie. Navrhovaná metodika rozvíja pôvodný váhový fuzzy model smerom k plne adaptívnemu rámcu – pravdepodobnostné odhady sa pri učení postupne vyhladzujú, informatívne interakcie medzi atribútmi sa identifikujú automaticky na základe vzájomnej informácie a nastavenie hyperparametrov zabezpečuje krížová validácia. Spoľahlivosť každého rozhodnutia sa kvantifikuje tromi komplementárnymi režimami, ktoré vyvažujú rýchlosť spracovania a presnosť. Týmto spojením interpolovaných pravdepodobností, dynamického výberu závislostí a viacúrovňového hodnotenia istoty vzniká flexibilný, interpretovateľný model, schopný udržiavať vysokú predikčnú presnosť aj pri meniacich sa dátových podmienkach.

1 TEORETICKÉ ZÁKLADY ANALÝZY SPOĽAHLIVOSTI DÁT

V tejto kapitole sa najprv definujú základné pojmy spoľahlivosti dát a identifikujú hlavné faktory, ktoré ju ovplyvňujú v moderných rozhodovacích a analytických systémoch. Cieľom je ukázať, prečo je spoľahlivosť vstupných dát kľúčová pre kvalitu výstupných modelov a rozhodnutí.

1.1 Spoľahlivosť údajov ako analytický problém

V prostredí rozhodovacích a analytických systémov sa spoľahlivosť dát (*data reliability*) chápe ako kvantitatívna miera dôvery vo vstupné hodnoty databázy počas ich následného spracovania, modelovania alebo podpory rozhodovania [Maimon2001]. Nedostatočná spoľahlivosť týchto dát vedie k chybovosti analytických záverov, k zníženiu presnosti strojovo učených modelov a k narušeniu prevádzkovej stability podnikových systémov [Maimon2001].

Ako zdôrazňujú Batini, nevyhovujúca kvalita dát predstavuje kľúčové riziko nielen pre technickú integritu analytických tokov, ale aj pre dôveru koncových používateľov, čo môže vyústiť do nesprávnych rozhodnutí na všetkých úrovniach spracovania dát [Batini2006].

Nasledujúca tabuľka sumarizuje hlavné kategórie týchto chýb spolu s typickými príkladmi a ich prevádzkovými dôsledkami.

Tabuľka 1 Typológia chýb ovplyvňujúcich spoľahlivosť údajov

Typ chyby	Príklady	Dôsledky
Chyby zadávania údajov	Preklepy, nesprávne formáty	Nevalidné hodnoty, výpadky logiky
Zastaranie údajov	Neaktuálne ceny, staré kontakty	Nejednoznačnosť, spomalenie spracovania
Šum, redundancia	Rozličné kódovanie, duplicitné záznamy	Nejednoznačnosť, spomalenie spracovania

1.1.1 Prístupy k zabezpečeniu kvality a spoľahlivosti údajov

Zabezpečenie kvality údajov je tradične súčasťou predspracovania dát v informačných systémoch a analytických nástrojoch. Hlavným cieľom je znížiť množstvo chýb, zvýšiť konzistenciu a zabezpečiť zmysluplnosť vstupných údajov pred ich ďalším využitím.

Prehľad týchto postupov, spolu s ich hlavnými prínosmi a limitačnými faktormi, uvádza nasledujúca tabuľka.

Tabuľka 2 Tradičné prístupy k zabezpečeniu kvality údajov

Prístup	Popis	Typické obmedzenia
Validácia údajov pri vkladaní	Overovanie formátu, rozsahu hodnôt a logických vzťahov medzi atribútmi.	Nie je možné predvídať všetky chyby. Chybná hodnota môže byť formálne správna.
Čistenie údajov (data cleansing)	Odstraňovanie duplikátov, dopĺňanie chýbajúcich hodnôt, oprava zrejmých chýb.	Mnohé chyby sa prejavia až neskôr. Niektoré zostávajú bez povšimnutia.
Korekcia údajov	Odhadovanie alebo nahrádzanie podozrivých hodnôt na základe doménových znalostí.	Náklady na úplnú verifikáciu sú vysoké, hlavne pri veľkých alebo realtime dátach

Preto sa v posledných rokoch vyvíjajú metódy pre gradované hodnotenie dôveryhodnosti údajov, ktoré namiesto binárneho delenia na „správne“ a „nesprávne“ umožňujú každému záznamu priradiť skóre spoľahlivosti na základe fuzzy techník [Sanchez2000].

1.1.2 Pojem „Zero Defect Data“ a jeho praktické limity

Koncept „Zero Defect Data“ predstavuje ideálny stav, podľa ktorého by všetky údaje v informačnom systéme mali byť absolútne presné, konzistentné a bez akýchkoľvek chýb [Wand1996]. Hoci táto predstava z hľadiska kvality dát dáva teoretický zmysel, jej implementácia v reálnych podmienkach narazí na viacero zásadných prekážok:

1. **Dynamickosť dátového prostredia.** Údaje sú kontinuálne generované a aktualizované z rôznych, často heterogénnych zdrojov, čo zvyšuje pravdepodobnosť nekonzistencií a systémových chýb.
2. **Technicko-ekonomická náročnosť.** Zabezpečenie úplnej bezchybnosti (100 % overenie každého záznamu) si vyžaduje enormné výpočtové zdroje a čas, najmä pri spracovaní veľkých dátových tokov v reálnom čase.

Vo finančnom sektore, v ktorom sa denne spracúvajú milióny transakcií, by zabezpečenie úplnej bezchybnosti údajov („Zero Defect Data“) vyžadovala 100 % overenie každej transakcie, čo je technicky nereálne a ekonomicky neefektívne.

3. **Potrebná znalostná kontextualizácia.** Niektoré chyby možno odhaliť len v priebehu biznis procesov alebo pri spätnej analýze; bez hĺbkového pochopenia doménových súvislostí zostávajú prehliadnuté až do neskorších fáz spracovania.

V dôsledku uvedených obmedzení sa dnes uprednostňuje pragmatickejší prístup, ktorý namiesto binárneho rozdelenia dát na „správne“ a „nesprávne“ zavádza koncept gradual data trust – postupnej dôveryhodnosti údajov. Tento framework umožňuje každému záznamu priradiť skóre spoľahlivosti na základe rôznych metrík (napr. časovej aktuálnosti, zdroja, konzistencie), a následne toto skóre zohľadniť v rozhodovacích procesoch.

1.2 Neurčitosť a fuzzy logika v hodnotení údajov

1.2.1 Lingvistické premenné

Dôležitou súčasťou fuzzy logiky sú tzv. lingvistické premenné. Ide o kvalitatívne pojmy, ktoré reprezentujú neurčité hodnoty. Príklady zahŕňajú výrazy ako „nízky tlak“, „stredný príjem“, „vysoké riziko“, „dôležitý zákazník“, „veľký balík“ alebo „slabá spoľahlivosť“. Takéto výrazy sú prístupnejšie pre človeka než presné numerické hodnoty a umožňujú počítačovým systémom pracovať s neurčitosťou prirodzenejším spôsobom. Fuzzy logika spracúva tieto výrazy prostredníctvom fuzzy množín, ktorým sa priraďujú funkcie príslušnosti.

1.2.2 Základy fuzzy logiky a množín

Tradičné relačné a analytické systémy predpokladajú, že každá logická podmienka nad dátami má presne dve hodnoty: pravda (1) alebo nepravda (0). Avšak v dôsledku šumu, neúplnosti či neistoty v reálnych dátach toto binárne rozlíšenie často nepostačuje [Maimon et al. 2001]. Fuzzy logika rieši túto nejednoznačnosť tým, že umožňuje zohľadniť gradácie pravdivosti.

Definícia fuzzy množiny. Nech X je univerzum diskurzu. Fuzzy množina $\tilde{A}$ na X je definovaná funkciou príslušnosti

$$\mu_{\tilde{A}}: X \rightarrow [0,1],$$

kde $\mu_{\tilde{A}}(x)$ udáva stupeň príslušnosti prvku x k množine $\tilde{A}$ [Klir & Yuan 1995]. Pôvodný koncept navrhol Lotfi A. Zadeh, pričom nahradil tvrdé členstvo 0/1 hladinou s hodnotami v intervale [0,1] [Zadeh1965].

Príklad:

Nech $\tilde{S}$ predstavuje fuzzy množinu „spokojný zákazník“ na univerze hodnotení{ nespokojný, neutrálny, spokojný}. Funkcia príslušnosti pri hodnotení 6 bodov (na škále od 0 do 10) môže byť definovaná ako:

$$\mu_{\text{nespokojný}}(6) = 0.0, \quad \mu_{\text{neutrálny}}(6) = 0.7, \quad \mu_{\text{spokojný}}(6) = 0.3.$$

Takáto definícia umožňuje zachytiť mieru, do akej sa konkrétny výsledok (6 bodov) zaraďuje k jednotlivým lingvistickým kategóriám, namiesto ostrého binárneho rozlíšenia [Zadeh1965].

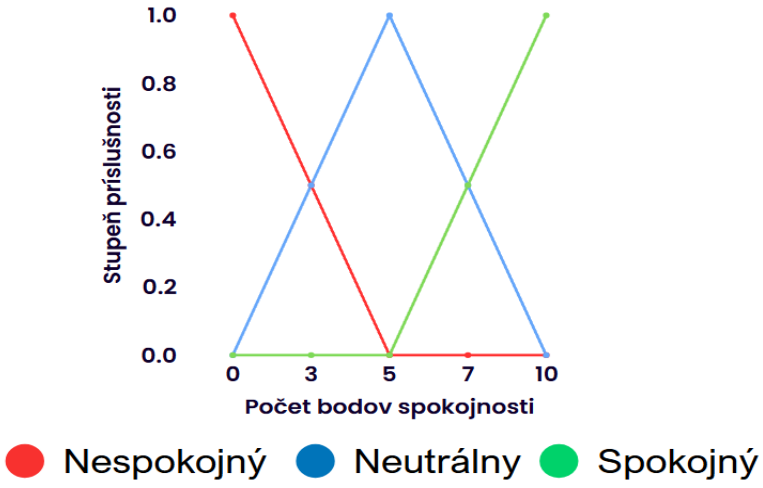

Obrázok 1 Funkcia príslušnosti pre kategórie spokojnosti zákazníka

1.3 Informačné miery a pravdepodobnostné modely

1.3.1 Entropia a informačný zisk

Entropia je základná veličina informačnej teórie, ktorá kvantifikuje mieru neurčitosti alebo náhodnosti spojenej s výskytom náhodnej premennej. Čím vyššia je entropia, tým väčšia je neistota ohľadom hodnoty danej premennej.

Definícia (Shannon 1948; Cover & Thomas 1991) :

Miera entropie náhodnej premennej X sa vypočíta ako

$$\boldsymbol{H(X) = -\sum_{i} p(x_{\mathrm{i}}) * \log_2 p(x_{\mathrm{i}})}$$

kde $p(x_i)$ je pravdepodobnosť, že X nadobudne hodnotu x_i, a suma prebieha cez všetky možné hodnoty x_i.

Príklad:

Ak má X tri možné hodnoty „low“, „med“ a „high“, každá s pravdepodobnosťou p = 1/3, dostaneme

$$\mathbf{H}(\boldsymbol{X}) = -\left(\mathbf{3} * \mathbf{1/3} * \mathbf{log_2}(\mathbf{1/3})\right) = \mathbf{log_2}(\mathbf{3}) \approx \mathbf{1.585}$$

V rozhodovacích úlohách sa často používa aj podmienená entropia, ktorá vyjadruje, koľko neistoty ostáva v cieľovej premennej Y, keď už poznáme hodnotu atribútu X:

$$\mathbf{H}(\boldsymbol{Y}|\boldsymbol{X}) = \sum \boldsymbol{p}(\boldsymbol{x}_\mathrm{i}) * \boldsymbol{H}(\boldsymbol{Y}|\boldsymbol{X} = \boldsymbol{x}_\mathrm{i})$$

alebo rozvinutá forma:

$$\boldsymbol{H}(\boldsymbol{Y} \mid \boldsymbol{X}) = -\sum_{\boldsymbol{i}} \sum_{\boldsymbol{j}} \boldsymbol{p}(\boldsymbol{x_i}, \boldsymbol{y_j})\ \mathbf{log_2}\, \boldsymbol{p}\left(\boldsymbol{y_j} \mid \boldsymbol{x_i}\right)$$

kde:

• $p(x_i, y_j)$ je spoločná pravdepodobnosť udalostí $X = x_i$ a $Y = y_j$,

• $p(y_j \mid x_i)$ je podmienená pravdepodobnosť triedy $Y = y_j$ za predpokladu $X = x_i$.

Podmienená entropia vyjadruje, koľko neistoty ostáva v triedach Y, ak už poznáme hodnoty atribútu X.

Na základe entropie sa definuje informačný zisk (Information Gain) ako rozdiel medzi celkovou entropiou $H(Y)$ a a podmienenou entropiou $H(Y|X)$:

$$\mathbf{IG}(\boldsymbol{Y}, \boldsymbol{X}) = \mathbf{H}(\boldsymbol{Y}) - \mathbf{H}(\boldsymbol{Y}|\boldsymbol{X})$$

Čím vyšší je informačný zisk, tým väčší vplyv má atribút X a významne znižuje neistotu ohľadom cieľovej premennej Y. Teda atribút X je informatívnejší.

1.3.2 Fuzzy entropia

V prípade, že údaje nie sú presne určené, ale majú charakter neistoty alebo nepresnosti (napr. „stredný“, „možno vysoký“), klasická entropia sa rozširuje na tzv. fuzzy entropiu.

Táto verzia entropie využíva stupne príslušnosti jednotlivých hodnôt k triedam a umožňuje tak vyjadriť neurčitosť aj pri neostrých údajoch. Fuzzy entropia sa počíta analogicky, ale namiesto presných pravdepodobností $p(x_i)$ sa používajú vážené stupne príslušnosti:

$$\boldsymbol{H_f(X) = -\sum \mu(x_i) * \log_2 \mu(x_i)}$$

kde:

- $\mu(x_i)$ je stupeň príslušnosti hodnoty x_i k danej triede ($0 \leq \mu \leq 1$).

Fuzzy entropia umožňuje pracovať s nepresnými, neúplnými alebo váhavými údajmi - čo je kľúčové pri analýze spoľahlivosti v reálnych systémoch.

1.3.3 Váhové pravdepodobnostné modely

V mnohých aplikáciách s neurčitými alebo čiastočne nespoľahlivými dátami nestačí striktne binárne rozhodovanie (správne / nesprávne). Váhové pravdepodobnostné modely preto pristupujú k úlohe klasifikácie tak, že všetky dostupné atribúty prispievajú súčasne, pričom každý príspevok je vážený podľa svojej informatívnosti [Maimon2001].

Pre daný atribút *i* a jeho konkrétnu hodnotu *x* definujeme:

$$\mathbf{P}(\boldsymbol{V = j | i = x})$$

ako pravdepodobnosť, že cieľová trieda *V* nadobudne hodnotu *j*, ak vieme, že atribút

i = *x*.

Tieto pravdepodobnosti sa premenia na váhové príspevky pomocou logaritmickej transformácie, ktorá sa nazýva logaritmické váhy.

Definujeme ich nasledovne:

$$\boldsymbol{w_{j;\, i=x_i} = \log_2 \left(\frac{P_{2k}(V = j \mid i = x_i)}{P_{2k}(V = j)} \right)}$$

Interpretácia:

- $\boldsymbol{w_{j;i=x}} > 0$: hodnota *i* = *x* zvyšuje dôveru v triedu *V* = *j.*
- $\boldsymbol{w_{j;i=x}} < 0$: hodnota *i* = *x* znižuje dôveru v triedu *V* = *j.*
- $\boldsymbol{w_{j;i=x}} = 0$: atribút je pre túto triedu neutrálny.

Keďže niektoré atribúty môžu mať vzájomné interakcie, samotné jednoduché váhy (pre každý atribút zvlášť) nemusia zachytiť všetku informatívnosť. Párové váhy merajú dodatočnú informáciu, ktorú poskytuje kombinácia dvoch atribútov nad rámec ich samostatných príspevkov [Cover & Thomas 1991; Maimon et al. 2001].

Definícia párovej váhy

$$\boldsymbol{w_{j;\, i^1=x^1,\, i^2=x^2} = \log_2 \left(\frac{P\left(V = j \,\middle|\, i^1 = x^1,\, i^2 = x^2\right)}{P(V = j)} \right)}$$

vyjadruje párovú váhu atribútov i^1 a i^2 pre predikciu triedy *V* = *j*.

Avšak pri obmedzenom počte vzoriek môžu priame frekvenčné odhady vykazovať vysokú variabilitu a viesť k nestabilným váham. Preto je nevyhnutné zaviesť mechanizmus, ktorý tieto odhady vyhladí a umožní postupnú adaptáciu modelu na rastúci objem dát. Nasledujúca časť sa preto venuje interpolácii pravdepodobností, ktorá spoľahlivo kombinuje apriórne znalosti s empirickými pozorovaniami.

1.3.4 Základné pravdepodobnostné distribúcie

Praktické modely často trpia nedostatkom spoľahlivých štatistík, najmä v počiatočných fázach učenia alebo pri výskyte zriedkavých kombinácií atribútov. Tento problém rieši iteratívna interpolácia pravdepodobností.

Empirická pravdepodobnosť triedy predstavuje relatívnu frekvenciu výskytu triedy *j* v trénovacej množine. Odhaduje sa priamo z údajov bez ohľadu na konkrétne hodnoty atribútov. [Bishop2006]

Definícia empirickej pravdepodobnosti

$$\boldsymbol{\hat{P}(V = j) = \frac{n_{V=j}}{n}}$$

kde:

- $n_{V=j}$ - počet prípadov, ktoré patria do triedy *j*,
- n - celkový počet pozorovaní.

Počas učenia modelu zo skutočných dát sa pravdepodobnosti nepoznajú vopred, ale musia sa odhadnúť z pozorovaných frekvencií. Ak chceme odhadnúť, aká je pravdepodobnosť, že prípad patrí do triedy j, za predpokladu, že určitý atribút *i* má hodnotu *x*, použijeme empirickú podmienenú pravdepodobnosť [Hastie2009]:

$$\boldsymbol{\hat{P}(V = j \mid i = x) = \frac{n_{i=x,\, V=j}}{n_{i=x}}}$$

kde:

$\hat{P}(V = j \mid i = x)$ - empirický odhad podmienenej pravdepodobnosti triedy *j* vzhľadom na hodnotu atribútu *x*,

$n_{i=x,\, V=j}$ - počet prípadov, kde atribút *i* má hodnotu *x* a trieda je *j*,

$n_{i=x}$ - celkový počet prípadov, kde atribút *i* má hodnotu *x*.

Empirické hodnoty - Odhady získané po zbere vzorky. Vyjadrujú relatívne frekvencie pozorovaných javov. Sú priamo odvodené z dát, rýchlo sa prispôsobujú novým informáciám, no pri malom počte pozorovaní môžu byť menej stabilné.

Definícia apriórnej pravdepodobnosti $\boldsymbol{\pi_j}$ vyjadruje východiskovú doménovú znalosť ešte pred spracovaním údajov[Gelman2013]

$$\boldsymbol{P(V = j) = \pi_j}$$

kde:

- V - cieľová premenná (napr. trieda),
- $j \in$ {1,...,C} - index triedy,
- $\pi_j \geq 0$, pričom $\sum_j \pi_j = 1$
- π_j môže byť:
  - rovnomerné: $\pi_j = \frac{1}{C}$
  - doménovo špecifické (napr. ak vieme, že niektoré triedy sa vyskytujú častejšie).

Apriórne hodnoty - Číselné parametre, ktoré stanovujú pravdepodobnosť či iný štatistický ukazovateľ pred zhromaždením aktuálnych dát. Opierajú sa o teoretické poznatky, historické merania alebo expertný úsudok a slúžia ako východisková informácia v modeli.

Marginálna pravdepodobnosť hodnoty atribútu vyjadruje pravdepodobnosť výskytu konkrétnej hodnoty atribútu bez ohľadu na iné premenné (atribúty alebo cieľové triedy). Získava sa sumovaním alebo integrovaním cez všetky možné hodnoty ostatných premenných v spoločnom rozdelení.

Definícia marginálnej pravdepodobnostihodnoty atribútu (bez ohľadu na triedu) sa získava súčtom cez všetky triedy [Cover1991]:

$$\boldsymbol{P(i = x) = \sum_j \hat{P}(V = j \mid i = x)}$$

To je empirická marginálna pravdepodobnosť - empirická, lebo pochádza z pozorovaní, marginálna, lebo ignoruje ostatné premenné.

Zatiaľ čo empirická pravdepodobnosť $\hat{P}(V = j \mid i = x)$ hovorí niečo o súvislosti medzi atribútom a triedou (teda závislej štruktúre), marginálna pravdepodobnosť sa pozerá len na frekvenciu výskytu jednej hodnoty v celkovom súbore.

2 ANALÝZA EXISTUJÚCICH PRÍSTUPOV A VÝBER METÓDY

2.1 Prístup založený na váhovom fuzzy modeli

2.1.1 Koncepcia a hlavné charakteristiky modelu v práci Maimon et al.

2.1.1.1 Cieľ a motivácia modelu

Tradičné prístupy ku klasifikácii údajov, ako sú napríklad rozhodovacie stromy, sú založené na selektívnom vetvení podľa hodnôt jednotlivých atribútov. Hoci tento prístup zabezpečuje interpretovateľnosť rozhodovacích procesov, vykazuje viaceré obmedzenia, ako napríklad obmedzenú schopnosť integrovať viacero zdrojov informácií, citlivosť na drobné odchýlky v údajoch a nedostatočnú podporu spracovania neurčitosti.

Model navrhnutý Maimonom a kolektívom [Maimon1998] ponúka alternatívny prístup k riešeniu týchto nedostatkov. Jeho základnou myšlienkou je agregácia informatívnych príspevkov všetkých dostupných atribútov do jednotného skóre pre každú triedu. Rozhodovanie následne prebieha na základe porovnania týchto agregovaných skóre, čím sa zabezpečuje simultánne a vážené využitie informácií z viacerých zdrojov.

Významnou vlastnosťou modelu je schopnosť pracovať s neurčitosťou údajov prostredníctvom interpolácie pravdepodobností. Okrem toho model umožňuje kvantifikovať mieru spoľahlivosti rozhodnutia použitím konceptu fuzzy reliability, čo zvyšuje jeho robustnosť a praktickú použiteľnosť pri analýze údajov s neistotou.

2.1.1.2 Interpolácia pravdepodobností v klasifikácii údajov

V reálnych údajoch je častým problémom nedostatok spoľahlivých štatistických údajov, najmä ak sa vyskytujú zriedkavé kombinácie hodnôt alebo model pracuje s obmedzeným množstvom dát. Namiesto priameho použitia empirických pravdepodobností preto model Maimona zavádza interpolované pravdepodobnosti označené ako P_{2k}.

Tieto pravdepodobnosti kombinujú historické odhady s aktuálne vypočítanými štatistikami.

2.1.1.2.1 Interpolácia apriórnych pravdepodobností

Interpolácia apriórnych pravdepodobností sa používa na odhad základnej pravdepodobnosti triedy V_{ij} bez ohľadu na konkrétne hodnoty vstupných atribútov.

Trieda V_{ij} reprezentuje stav výstupnej premennej, kde *i* označuje index atribútu a *j* jeho konkrétnu hodnotu. Napríklad, ak atribút *i* predstavuje "vek" a *j* hodnotu "mladý", potom V_{ij} znamená "vek = mladý".

Interpolácia kombinuje dve zložky:

- $Pr(V_{ij})$ – apriórne rozdelenie tried na základe predchádzajúcich znalostí alebo doménových očakávaní. (pozri v 1.3.4).
- $P_{1k}(V_{ij})$ – aktuálne empirické rozdelenie tried na základe údajov zhromaždených počas *k*-tej iterácie učenia(pozri v 1.3.4).

Interpolovaný odhad pravdepodobnosti $P_{2k}(V_{ij})$ sa potom vypočíta podľa vzorca:

$$\boldsymbol{P_{2k}(V_{ij}) = (1-\alpha)\cdot Pr(V_{ij}) + \alpha\cdot P_{1k}(V_{ij})}$$

Kde:

- α je hyperparameter ($0 \le \alpha \le 1$), ktorý určuje váhu aktuálnych údajov v porovnaní s apriórnym predpokladom,
- $(1-\alpha)$ určuje váhu pôvodnej predpokladanej pravdepodobnosti.

2.1.1.2.2 Interpolácia jednoduchých podmienených pravdepodobností

Interpolácia jednoduchých podmienených pravdepodobností sa používa na odhad pravdepodobnosti triedy V_{ij} vzhľadom na známu hodnotu jedného konkrétneho vstupného atribútu $V_{i'j'}$.

Trieda V_{ij} reprezentuje stav cieľovej (výstupnej) premennej, kde *i* označuje index atribútu a *j* jeho konkrétnu hodnotu. Premenná $V_{i'j'}$ predstavuje konkrétnu známu hodnotu vstupného atribútu, ktorá ovplyvňuje predikciu výstupu.

Interpolácia kombinuje dve zložky:

- $\boldsymbol{P_{2k}(V_{ij})}$ – interpolovanú apriórnu pravdepodobnosť triedy po predchádzajúcich iteráciách učenia.
- $\boldsymbol{P_{1k}(V_{ij} \mid V_{i'j'})}$ – aktuálne empirické odhadnutie podmienenej pravdepodobnosti triedy vzhľadom na hodnotu atribútu.

Interpolovaná podmienená pravdepodobnosť sa vypočíta podľa vzorca:

$$\boldsymbol{P_{2k}(V_{ij} \mid V_{i'j'}) = (1-\beta)\cdot P_{2k}(V_{ij}) + \beta\cdot P_{1k}(V_{ij} \mid V_{i'j'})}$$

Kde:

- $\boldsymbol{P_{2k}(V_{ij} \mid V_{i'j'})}$ – výsledná interpolovaná podmienená pravdepodobnosť.

- ***β*** – váhový parameter, ktorý riadi dôveru v nové pozorovania (0 ≤ β ≤ 1).

Čím väčšia je hodnota *β*, tým viac model dôveruje novým údajom. Pri nižšej hodnote *β* model kladie väčší dôraz na historické odhady.

2.1.1.2.3 Interpolácia párových pravdepodobností

Interpolácia párových pravdepodobností sa používa na zlepšenie odhadu spoločnej pravdepodobnosti triedy V_{ij} na základe známych hodnôt dvoch rôznych atribútov $V_{i'j'}$ a $V_{i''j''}$. Tento prístup je kľúčový pre zachytenie interakcií medzi atribútmi, ktoré by pri samostatnom hodnotení nemuseli byť zrejmé.

Pri interpolácii párových pravdepodobností kombinujeme dva odhady:

- Nezávislý odhad: predpokladáme, že atribúty $V_{i'j'}$ a $V_{i''j''}$ sú podmienečne nezávislé.
- Empirický odhad: vychádzame z reálne pozorovanej spoločnej štatistiky.

Výsledná interpolovaná pravdepodobnosť je vážený priemer týchto dvoch prístupov. Výpočet interpolácie je daný vzorcom:

$$P_{2k}\left(V_{ij} \mid V_{i'j'}, V_{i''j''}\right) = \left(1 - \gamma(k)\right) \cdot \left(\frac{P_{2k}\left(V_{ij} \mid V_{i'j'}\right) \cdot P_{2k}\left(V_{ij} \mid V_{i''j''}\right)}{P_{2k}(V_{ij})}\right) + \gamma(k) \cdot P_{1k}\left(V_{ij} \mid V_{i'j'}, V_{i''j''}\right)$$

Kde:

- $P_{2k}(V_{ij} \mid V_{i'j'}, V_{i''j''})$ je interpolovaná podmienená pravdepodobnosť triedy V_{ij} vzhľadom na dve hodnoty atribútov.
- $\gamma(k)$ je váhový parameter interpolácie, ktorý závisí od iterácie **k**.
- $P_{2k}(V_{ij} \mid V_{i'j'})$ a $P_{2k}(V_{ij} \mid V_{i''j''})$ sú jednoduché podmienené pravdepodobnosti.
- $P_{2k}(V_{ij})$ je interpolovaná apriórna pravdepodobnosť triedy.
- $P_{1k}(V_{ij} \mid V_{i'j'}, V_{i''j''})$ je empiricky pozorovaná spoločná pravdepodobnosť triedy V_{ij} vzhľadom na dvojicu atribútov.

Parameter $\gamma(k)$ umožňuje modelu dynamicky meniť váhu medzi nezávislým odhadom a empirickým pozorovaním v závislosti od dostupnosti a spoľahlivosti údajov:

- Na začiatku učenia, keď je málo dát, $\gamma(k)$ býva malé a preferuje sa nezávislý odhad.
- S pribúdajúcimi iteráciami $\gamma(k)$ rastie a model sa viac spolieha na empiricky pozorované závislosti.

Tento mechanizmus interpolácie je zásadný pre robustné učenie v podmienkach nedostatku alebo neúplnosti dát.

Priklad:

Majme zákaznícky servis, ktorý eviduje čas, počas ktorého klient čakal na obsluhu, subjektívne hodnotenie kvality vyriešenia požiadavky, spôsob vystupovania zamestnanca a náročnosť riešeného problému.

Naším cieľom je na základe týchto štyroch pozorovateľných atribútov čo najpresnejšie určiť, do akej miery bude klient po ukončení interakcie spokojný.

Namerané údaje zhrnuté v

Tabuľka 3 Východiskový minidataset pre demonstráciu modelubudeme ďalej využívať na odhad chýbajúcej spokojnosti pri 10. zázname (označenom „?“) a na výpočet všetkých nadväzujúcich pravdepodobností a váh.

Tabuľka 3 Východiskový minidataset pre demonstráciu modelu

ID	T – čas čakania	Q – kvalita riešenia	P – prístup zamestnanca	C – zložitosť problému	V – spokojnosť
1	krátky	vysoká	priateľský	stredný	spokojný
2	krátky	stredná	neutrálne	jednoduchý	spokojný
3	stredný	nízka	neutrálne	zložitý	nespokojný
4	dlhý	vysoká	priateľský	zložitý	neutrálny
5	dlhý	nízka	nezdvorilý	stredný	nespokojný
6	stredný	stredná	priateľský	jednoduchý	neutrálny
7	krátky	nízka	nezdvorilý	stredný	nespokojný
8	dlhý	stredná	neutrálne	zložitý	neutrálny
9	stredný	vysoká	priateľský	jednoduchý	spokojný
10	stredný	stredná	neutrálne	zložitý	? (neznáma)

Cieľová premenná *V* nadobúda kategórie {nespokojný, neutrálny, spokojný}.

Krok1. Empirické (frekvenčné) odhady

Krok1A. Marginálne frekvencie tried

$$\widehat{\boldsymbol{P}}(\boldsymbol{V}=\boldsymbol{j})=\frac{\boldsymbol{n}_{\boldsymbol{V}=\boldsymbol{j}}}{\boldsymbol{n}},\mathbf{n}=\mathbf{9}$$

Tabuľka 4 Marginálne frekvencie cieľovej premennej V

Trieda	$\boldsymbol{n_{V=j}}$	$\boldsymbol{\widehat{P}(V=j)}$
spokojný	3	0,333
neutrálny	3	0,333
nespokojný	3	0,333

Predpokladáme rovnomerné apriórne rozdelenie

$\boldsymbol{\pi_j}$ =1/3, čo je v súlade s empirickým zistením.

Krok2B. Podmienené frekvencie pre *T* = *stredný*

$$n_{T=stredny} = 3$$

Tabuľka 5 Podmienené frekvencie tried V pre hodnotu T = „stredný“

Trieda	$\boldsymbol{n_{T,V}}$	$\boldsymbol{\widehat{P}(V=j \mid T)}$
spokojný	1	0,333
neutrálny	1	0,333
nespokojný	1	0,333

Krok1C. Podmienené frekvencie pre *Q* = *stredn*á

$$n_{Q=stredná} = 3$$

Tabuľka 6 Podmienené frekvencie tried V pre hodnotu *Q* = „stredná“

Trieda	$\boldsymbol{n_{Q,V}}$	$\boldsymbol{\widehat{P}(V=j \mid Q)}$
spokojný	1	0,333
neutrálny	2	0,667
nespokojný	0	0,000

Krok1D. Spoločná frekvencia páru (*T*,*Q*)=(*stredný*, *stredn*á)

Kombinácia sa vyskytla raz (záznam 6, trieda *neutrálny*).

$$P(V=j \mid T,Q) = \begin{cases} 1, neutra\acute{}lny \\ 0, \qquad inak \end{cases}$$

Krok2. Interpolácia apriórnych pravdepodobností

Váhový parameter: α=0,6

Interpolácia sa vykoná pre každú triedu samostatne:

$$\boldsymbol{P_{2k}(V_{ij}) = (1-\alpha)\cdot Pr(V_{ij}) + \alpha\cdot P_{1k}(V_{ij})}$$

Krok2A. Trieda *spokojný*

$$\boldsymbol{P_{2k}(V\ = spokojn}\text{ý}) = (1-0.6)\cdot\frac{\mathbf{1}}{\mathbf{3}} + \mathbf{0.6}\cdot\frac{\mathbf{1}}{\mathbf{3}}\ =\ \mathbf{0,333}$$

Krok2B. Trieda *neutrálny*

$$\boldsymbol{P_{2k}(V\ = neutr\text{á}lny}) = (1-0.6)\cdot\frac{\mathbf{1}}{\mathbf{3}} + \mathbf{0.6}\cdot\frac{\mathbf{1}}{\mathbf{3}}\ =\ \mathbf{0,333}$$

Krok2C. Trieda *nespokojný*

$$\boldsymbol{P_{2k}(V\ = nespokojn}\text{ý}) = (1-0.6)\cdot\frac{\mathbf{1}}{\mathbf{3}} + \mathbf{0.6}\cdot\frac{\mathbf{1}}{\mathbf{3}}\ =\ \frac{\mathbf{1}}{\mathbf{3}}$$

Krok3. Interpolácia jednoduchých podmienených pravdepodobností

Váhový parameter: *β*=0,6

$$\boldsymbol{P_{2k}(V_{ij}\mid V_{i'j'}) = (1-\beta)\cdot P_{2k}(V_{ij}) + \beta\cdot P_{1k}(V_{ij}\mid V_{i'j'})}$$

Krok3A. Prípad *A* = *T* = *stredný*

$\widehat{\boldsymbol{P}}(\boldsymbol{V=j}\mid\boldsymbol{T}) = \frac{\mathbf{1}}{\mathbf{3}}$ pre všetky *j*

$$\boldsymbol{P_{2k}}(V=j\mid T)\ =\ (1-0.6)\cdot\frac{1}{3} + 0.6\cdot\frac{1}{3}\ =\ \frac{\mathbf{1}}{\mathbf{3}}$$

Výsledok: rozdelenie zostalo presne rovnomerné, pretože apriórna aj empirická zložka sú identické.

Krok3B. Prípad *A* = *Q* = *stredný*

$\widehat{\boldsymbol{P}}(\text{spokojný}\mid\boldsymbol{Q})\ =\ \frac{\mathbf{1}}{\mathbf{3}}$

$\widehat{\boldsymbol{P}}(\text{neutrálny}\mid\boldsymbol{Q})\ =\ \frac{\mathbf{2}}{\mathbf{3}}$

$\widehat{\boldsymbol{P}}(\text{nespokojný}\mid\boldsymbol{Q})\ =\ 0$

Dosadenie:

Tabuľka 7 Vyhladené podmienené pravdepodobnosti pre hodnotu Q = „stredná“(β=0,6)

Trieda *j*	$(\mathbf{1}-\boldsymbol{\beta})\cdot \boldsymbol{P_{2k}}(\boldsymbol{V_{ij}})+\boldsymbol{\beta}\cdot \boldsymbol{P_{1k}}(\boldsymbol{V_{ij}} \mid \boldsymbol{V_{i'j'}})$	$\boldsymbol{P_{2k}}(\boldsymbol{V_{ij}} \mid \boldsymbol{V_{i'j'}})$
spokojný	$(1-0.6)\cdot\frac{1}{3}+0.6\cdot\frac{1}{3}$	0,333
neutrálny	$(1-0.6)\cdot\frac{1}{3}+0.6\cdot\frac{2}{3}$	0,533
nespokojný	$(1-0.6)\cdot\frac{1}{3}+0.6\cdot\frac{0}{3}$	0,133

stredná kvalita riešenia zvyšuje pravdepodobnosť neutrality (0,533) a zároveň potláča nespokojnosť (0,133)

Krok4. Nezávislý odhad párovej pravdepodobnosti

Pri malom počte pozorovaní predpokladáme, že atribúty *T* a *Q* sú podmienečne nezávislé vzhľadom na triedu *V.*

Dosadíme vyhladené hodnoty z krokov 2 a 3 (T = *stredný*, Q = *stredná*).

$$\boldsymbol{P}_{\boldsymbol{2k}}^{\boldsymbol{nezavisly}}(\boldsymbol{V}=\boldsymbol{j} \mid \boldsymbol{T},\boldsymbol{Q}) = \left(\frac{\boldsymbol{P_{2k}}(\boldsymbol{V}=\boldsymbol{j} \mid \boldsymbol{T})\cdot \boldsymbol{P_{2k}}(\boldsymbol{V}=\boldsymbol{j} \mid \boldsymbol{Q})}{\boldsymbol{P_{2k}}(\boldsymbol{V}=\boldsymbol{j})}\right)$$

Dosadíme vyhladené hodnoty z krokov 2 a 3 (T = *stredný*, Q = *stredná*).

Tabuľka 8 Nezávislý odhad párovej pravdepodobnosti pre kombináciu T = „stredný“ a Q = „stredná“

Trieda *j*	**Výpočet**	$\boldsymbol{P}_{\boldsymbol{2k}}^{\boldsymbol{nezavisly}}(\boldsymbol{V}=\boldsymbol{j} \mid \boldsymbol{T},\boldsymbol{Q})$
spokojný	$\frac{0{,}333\cdot 0{,}333}{0{,}333}$	0,333
neutrálny	$\frac{0{,}333\cdot 0{,}533}{0{,}333}$	0,533
nespokojný	$\frac{0{,}333\cdot 0{,}133}{0{,}333}$	0,133

Krok5. Váhový parameter *γ*(k)

Váha *γ*(k) určuje, koľko dôverujeme skutočnej spoločnej štatistike oproti nezávislému odhadu. Nech je

$$\gamma(\mathrm{k}) = \frac{n_{\leq k}^{(T,Q)}}{n_{\leq k}^{(T,Q)}+C}, \text{ C =4}$$

Pre dvojicu(T,Q)=(stredný,stredná) máme v prvých 9 záznamoch **jedno** pozorovanie

$n_{\leq k}^{(T,Q)} = 1 \rightarrow \gamma(2)$ = 0,2

Krok6. Interpolovaná párová pravdepodobnosť

$$\boldsymbol{P_{2k}(V = j \mid T, Q) = \left(1 - \gamma(k)\right) \cdot P_{2k}^{nezavisly}(V = j \mid T, Q) + \gamma(k) \cdot P_{1k}(V = j \mid T, Q)}$$

Spoločná empirická pravdepodobnosť $\boldsymbol{P_{1k}(V = j \mid T, Q)}$:

$\boldsymbol{P_{1k}(neutrálny \mid T, Q)}$ = 1, ostatné triedy 0.

Tabuľka 9 Interpolovaná párová pravdepodobnosť pre dvojicu T = „stredný“ a Q=„stredná“

Trieda *j*	$\left(1 - \gamma(k)\right) \cdot P_{2k}^{nezavisly}$	$\gamma(k) \cdot P_{1k}(V = j \mid T, Q)$	$P_{2k}(V = j \mid T, Q)$
spokojný	$0{,}8 \cdot 0{,}333 = 0{,}267$	$0{,}2 \cdot 0 = 0{,}000$	$0{,}267$
neutrálny	$0{,}8 \cdot 0{,}533 = 0{,}427$	$0{,}2 \cdot 1 = 0{,}200$	$0{,}627$
nespokojný	$0{,}8 \cdot 0{,}133 = 0{,}107$	$0{,}2 \cdot 0 = 0{,}000$	$0{,}107$

Krok7. Interpretácia výsledku

V ukážke sme zámerne rozpracovali iba dvojicu atribútov T=Čas čakania a Q=Kvalita riešenia aby bol proces interpolácie párových pravdepodobností zreteľný krok za krokom. Rovnaký postup by sa analogicky aplikoval aj na iné kombinácie, napr. (T×P, Q×C, P×C). Kvôli limitovanému počtu pozorovaní (n=9) by však väčšina takých buniek mala nulové frekvencie a váha *γ*(k) by ostala zanedbateľná.

2.1.1.3 Jednoduché váhové príspevky atribútov

Prvým krokom pri výpočte aktivačného skóre triedy je určenie informatívnych príspevkov jednotlivých atribútov. Každý vstupný atribút *i* so svojou hodnotou x_i môže prispieť k určitej triede *j*, a tento príspevok je vyjadrený ako váha:

$$\boldsymbol{w_{j;\, i=x_i} = \log_2\left(\frac{P_{2k}(V = j \mid i = x_i)}{P_{2k}(V = j)}\right)}$$

Táto rovnica zachytáva, o koľko sa zvýši dôveryhodnosť v triedu *j*, ak vieme, že atribút *i* má hodnotu x_i. Ide o logaritmický pomer medzi podmienenou pravdepodobnosťou a apriórnou pravdepodobnosťou, teda množstvo informácie, ktorú hodnota x_i prináša pre klasifikáciu do triedy *j*.

V prípade, že podmienená pravdepodobnosť je vyššia ako apriórna, váha bude kladná - daný atribút podporuje triedu. Ak je nižšia, váha je záporná – daný atribút hovorí proti triede. Ak sú rovnaké, váha je nulová a atribút je z hľadiska rozlíšenia triedy neutrálny.

Tieto jednoduché váhy tvoria základ pre výpočet skóre triedy, avšak nezohľadňujú vzťahy medzi dvojicami atribútov, ktoré môžu poskytovať dodatočnú, kombinovanú informáciu. Tento nedostatok je riešený v nasledujúcej časti modelu.

2.1.1.4 Párové váhy atribútov

Jednoduché váhy atribútov vychádzajú z predpokladu, že každý vstupný znak prispieva k predikcii nezávisle. V praxi však často existujú kombinované efekty medzi dvojicami atribútov, ktoré môžu výrazne ovplyvniť klasifikáciu. Aby model zachytil tieto komplexné vzťahy, zavádza tzv. párové váhy.

Tieto váhy predstavujú informatívny príspevok kombinácie dvoch atribútov k určitej triede. Označujú sa ako:

$$\boldsymbol{w_{j;i1=x1,i2=x2}}$$

Výpočet párovej váhy vychádza z nadbytočnej vzájomnej informácie, teda z množstva dodatočnej informácie, ktorú poskytujú dva znaky spoločne v porovnaní s ich samostatnými príspevkami. Vzorec pre výpočet má nasledujúcu podobu:

$$\boldsymbol{w^{ij}_{x'j',i''j''}(k)} = \mathbf{log}_2\left(\frac{\boldsymbol{P_{2k}\left(V_{ij}|V_{i'j'},V_{i''j''}\right)}}{\boldsymbol{P_{2k}(V_{ij})}}\right) - \mathbf{log}_2\left(\frac{\boldsymbol{P_{2k}\left(V_{ij}|V_{i'j'}\right)}}{\boldsymbol{P_{2k}(V_{ij})}}\right) - \mathbf{log}_2\left(\frac{\boldsymbol{P_{2k}\left(V_{ij}|V_{i''j''}\right)}}{\boldsymbol{P_{2k}(V_{ij})}}\right)$$

Táto rovnica vyjadruje čistý informatívny prínos kombinácie dvoch atribútov. Ak obidva znaky poskytujú samostatne určitú mieru informácie, ale ich kombinácia poskytuje výrazne viac, výsledná váha je kladná. Naopak, ak kombinácia neprináša nič nové oproti samostatným vplyvom, výsledok bude blízky nule alebo dokonca záporný.

Párové váhy tak umožňujú modelu zachytiť zložité interakcie medzi atribútmi, ktoré by pri samostatnom hodnotení mohli zostať neodhalené. Typickým príkladom môže byť situácia, keď kombinácia „veľký príjem“ a „mladý vek“ má zásadne odlišný význam pre predikciu triedy v porovnaní s každým atribútom osobitne.

Príklad výpočtu párovej váhy atribútov

$$\boldsymbol{w^{V=neutralna}_{T=stredny,Q=stredna}(k)}$$

Vstupné pravdepodobnosti (už-spočítané vyššie)

Tabuľka 10 Vstupné pravdepodobnosti, ktoré slúžia ako podklad pre výpočet párovej váhy

Trieda *j*	**$P_{2k}(V = j)$**	$P_{2k}(V = j \mid T)$	$P_{2k}(V = j \mid Q)$	$P_{2k}(V = j \mid T, Q)$
spokojný	0,333	0,333	0,333	0,267
neutrálny	0,333	0,333	0,533	0,627
nespokojný	0,333	0,333	0,133	0,107

Zdroj: kroky 2 – 6 kapitoly 2.1.1.2.3.

Krok1. Relatívne pomery

$$R_j^{TQ} = \frac{P_{2k}(V = j \mid T, Q)}{P_{2k}(V=j)}, R_j^T = \frac{P_{2k}(V = j|T)}{P_{2k}(V=j)}, R_j^Q = \frac{P_{2k}(V = j|Q)}{P_{2k}(V=j)}.$$

Tabuľka 11 Relatívne pomery pravdepodobností pre kombináciu T (stredný) × Q (stredná)

j	R_j^{TQ}	R_j^T	R_j^Q
spokojný	0,801	1,000	1,000
neutrálny	1,884	1,000	1,600
nespokojný	0,321	1,000	0,399

Krok2. Logaritmy

$$L_j^{TQ} = \log_2 R_j^{TQ}, \qquad L_j^T = \log_2 R_j^T, \qquad L_j^Q = \log_2 R_j^Q$$

Tabuľka 12 Logaritmy relatívnych pomerov pre T = stredný a Q = stredná

j	L_j^{TQ}	L_j^T	L_j^Q
spokojný	-0,319	0	0
neutrálny	0,913	0	0,679
nespokojný	-1,638	0	-1,324

Člen L_j^T je nulový len preto, že pri *T=stredny* nepozorujeme rozdiel medzi triedami; pri iných hodnotách *T* by sa premietol do váhy.

Krok3. Párová váha

$$w^{V=neutralna}_{T=stredny,Q=stredna}(k) = L_j^{TQ} - L_j^T - L_j^Q$$

Tabuľka 13 Výpočet párovej váhy pre kombináciu T = stredný a Q = stredná

j	**Výpočet**	$w^{V=neutralna}_{T=stredny,Q=stredna}$
spokojný	$-0{,}319 - 0 - 0$	-0,319
neutrálny	$0{,}913 - 0 - 0{,}679$	0,234
nespokojný	$-1{,}638 - 0 - (-1{,}324)$	-0,314

Interpretácia

Kombinácia atribútov „stredný čas čakania“ a „stredná kvalita riešenia“ poskytuje modelu dodatočnú diskriminačnú informáciu práve v prospech triedy neutrálny; jej synergický účinok presahuje to, čo by sa dalo očakávať zo samostatného vplyvu každého zo znakov. Naopak, pre triedy spokojný a nespokojný táto dvojica neobohacuje rozhodovanie – pridaná hodnota sa javí zanedbateľná, respektíve mierne potlačujúca ich individuálne príspevky.

2.1.1.5 Spoľahlivosť rozhodnutia

Informačne vážený klasifikačný model využíva agregačnú logaritmickú funkciu, ktorá sumarizuje všetku dostupnú evidenciu o triede prostredníctvom váhových príspevkov jednotlivých znakov aj ich informatívnych dvojíc. Takto získané skóre tvorí základ pre odhad triedy aj mieru spoľahlivosti rozhodnutia.

Logaritmická agregácia informácie

Pre každú triedu j sa vypočíta agregované skóre:

$$A_j = \log_2 \mathrm{P}_2(V = j) + \sum_i w_{j;i=x_i} + \sum_{(i^1,i^2)\in D} w_{j;i^1=x^1,i^2=x^2}$$

kde:

- $\log_2 \mathrm{P}(V = j)$ je logaritmus apriórnej pravdepodobnosti triedy,
- $w_{j;i=x_i}$ - váha jednotlivého atribútu (2.1.1.3),
- $w_{j;i^1=x^1,i^2=x^2}$ - váha dvojice atribútov (2.1.1.4).
- **D** – množina závislých párov vybraná dynamicky podľa vzájomnej informácie (2.1.2.1).

Skóre $\boldsymbol{A_j}$ predstavuje celkové množstvo evidencie v prospech triedy *j*.

Predikovaná trieda je určená ako tá, ktorá má najvyššie agregované skóre:

$$\mathbf{y} = \boldsymbol{arg\,\underset{j}{max}\,A_j}$$

Takto vypočítané skóre je výsledkom kombinácie všetkých známych faktorov, pričom každý z nich prispieva informáciou o triede. Tieto príspevky sú založené na podmienených pravdepodobnostiach a preto ich možno interpretovať ako informačné miery. Vyššia váha znamená vyšší informačný prínos konkrétneho znaku o výskyte triedy.

Odchýlka istoty

Ak skutočný (požadovaný) štítok príkladu označíme $\boldsymbol{A}_{\mathbf{actual}}$, definujeme rozdiel

$$\boldsymbol{d} = \boldsymbol{A}_{\mathbf{max}} - \boldsymbol{A}_{\mathbf{actual}}$$

Tento rozdiel d vyjadruje, o koľko bola zvolená trieda slabšia než najsilnejšia možná trieda. Ak *d* = 0, znamená to, že model bol plne presvedčený o svojej voľbe A_{actual} sa rovná A_{max}. Naopak, ak je d veľké, zvolená trieda je vzdialená od najviac podporovanej, čo naznačuje neistotu alebo nerozhodnosť.

Na základe tejto odchýlky sa spočíta fuzzy miera dôvery R:

$$\mathbf{R} = \frac{\mathbf{2}}{\mathbf{1} + \mathbf{exp}(-\boldsymbol{\lambda} \cdot \boldsymbol{d})}$$

Tento výpočet má niekoľko dôležitých vlastností:

- R = 1 znamená, že d = 0, teda rozhodnutie je úplne spoľahlivé (100 % istota).
- R sa blíži k 2, keď je d veľké - čo indikuje veľmi nízku spoľahlivosť (prakticky 0 % istota).
- R sa nikdy nevráti hodnotu 0, ale asymptoticky sa k nej približuje.

Spoľahlivosť R je teda kľúčovým nástrojom na odhad istoty modelu, najmä ak sa používa v reálnom prostredí s neistotou a fuzzy údajmi.

Vplyv dynamického výberu párov na spoľahlivosť

Keď sa k agregácii (1) pridajú len tie dvojice atribútov, ktorých vzájomná informácia prekročí prah ε, model sa vyhne šumu a zlepší diskriminačnú schopnosť:

- pri informatívnom páre vzrastie niektoré $\boldsymbol{w}_{j;i^1=x^1,i^2=x^2}$ → zvýši sa príslušné $\boldsymbol{A_j}$,
- tým sa často zväčší rozdiel $\boldsymbol{A}_{\mathbf{max}} - \boldsymbol{A}_{\mathbf{actual}}$, čím sa zmenší $\boldsymbol{d}$ a spoľahlivosť *R* klesne smerom k hodnote 1 (žiaduca situácia).

Naopak, páry so zanedbateľnou MI sa vypúšťajú; ich váhy ostávajú nulové, takže model sa zbytočne *nezriedi* nerelevantnými informáciami.

2.1.1.6 Postup výpočtu vo váhovom fuzzy modeli

V tejto časti popíšeme postup, ako model spracováva jednotlivý príklad od vstupu až po výstup spoľahlivej predikcie.

Krok 1. Načítanie a predspracovanie údajov

Najskôr sa údaje načítajú z databázy alebo vstupného súboru. Každý príklad obsahuje niekoľko vstupných atribútov a ich konkrétne hodnoty. V tomto kroku môže dôjsť k predspracovaniu údajov, ako je kódovanie kategórií, štandardizácia.

Krok 2. Výpočet váhových príspevkov atribútov

Pre každú triedu *j* sa vypočíta váhový príspevok každého atribútu *i* s hodnotou x_i . Individuálne váhy sú definované podľa metodiky uvedenej v časti 2.1.1.3. V prípade dostupnosti párových váh sa zohľadňujú aj kombinácie dvojíc atribútov, ako je podrobnejšie vysvetlené v časti 2.1.1.4. Tým sa kvantifikuje informatívnosť jednotlivých hodnôt atribútov vzhľadom na danú triedu.

Krok 3. Výpočet agregovaného skóre

Pre každú triedu j sa sčíta jej apriórna pravdepodobnosť a všetky príspevky atribútov:

Týmto sa pre každú triedu vypočíta skóre A_j, ktoré reprezentuje mieru podpory od údajov.

Krok 4. Určenie predikovanej triedy

Predikcia sa vykoná výberom triedy, ktorá má najvyššie agregované skóre:

$$\mathrm{y} = \arg\max_j A_j$$

Trieda *y* je teda považovaná za najpravdepodobnejšiu vzhľadom na vstupné údaje.

Krok 5. Výpočet spoľahlivosti rozhodnutia

Po určení predikcie sa vypočíta fuzzy miera dôvery R ako funkcia rozdielu medzi najvyšším skóre $A_{\max}$ a skóre predikovanej triedy A_{actual}, pričom výpočet spoľahlivosti je detailne opísaný v časti 2.1.1.5.

Hodnota R ∈ ⟨1, 2⟩ vyjadruje mieru istoty rozhodnutia, pričom hodnota bližšia k 1 naznačuje vyššiu spoľahlivosť a hodnota bližšia k 2 vyššiu neistotu.

Krok 6. Výstup a interpretácia výsledkov

Výsledkom algoritmu je predikovaná trieda spolu s mierou dôvery *R*. Tieto hodnoty môžu byť následne použité na rozhodovanie, vizualizáciu alebo spätnú väzbu pre ďalšie učenie modelu.

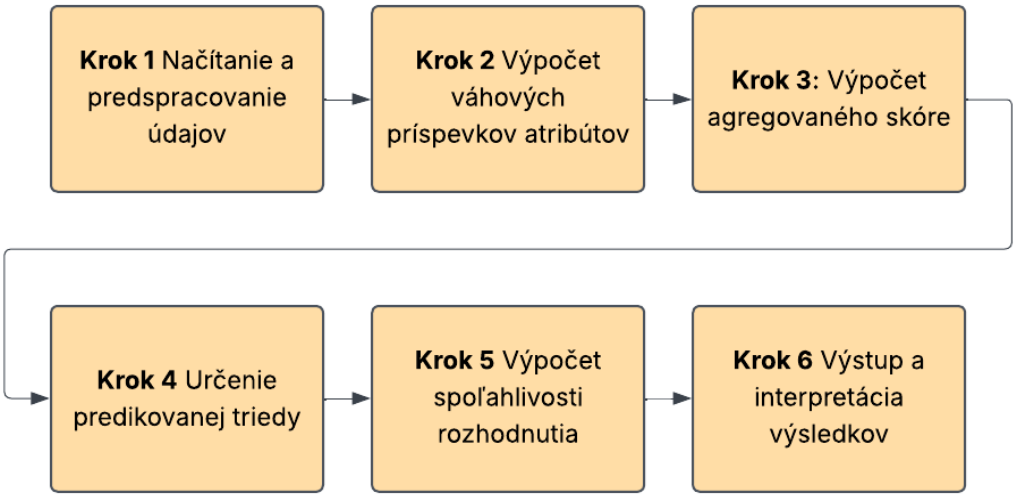

Obrázok 2 Procesný cyklus fuzzy klasifikátora – od dát k spoľahlivej predik

2.1.2 Rozšírenia váhového fuzzy modelu pre zvýšenie presnosti a robustnosti

Pôvodný model podľa Maimon et al. [Maimon2001] predstavuje robustný rámec na hodnotenie spoľahlivosti údajov. Analýza slabých miest pôvodného prístupu však odhalila potrebu zvýšenia praktickej použiteľnosti, presnosti a adaptability.

Model bol rozšírený o nasledovné kľúčové prvky:

- Dynamický výber závislých párov atribútov na základe miery vzájomnej informácie (mutual information).
- Automatický výber hyperparametrov pomocou krosvalidácie.
- Rozšírené režimy hodnotenia spoľahlivosti, vrátane novej stratégie batched-end reliability.

Tieto rozšírenia umožňujú modelu lepšie sa prispôsobiť rôznym typom údajov, minimalizovať vplyv nerelevantných alebo redundantných atribútov a poskytovať presnejšie odhady spoľahlivosti aj v náročných podmienkach online učenia.

V ďalších podkapitolách podrobne rozoberieme motiváciu, implementáciu a prínosy každej z týchto zmien.

2.1.2.1 Dynamický výber závislých párov atribútov na základe miery vzájomnej informácie

V pôvodnom modeli [Maimon2001] bola štruktúra závislostí medzi atribútmi fixne definovaná, pričom sa explicitne predpokladalo, že páry závislých znakov sú známe a nemenia sa. Tento prístup však vykazuje viaceré zásadné obmedzenia:

- V reálnych dátach často nie je vopred známe, ktoré dvojice atribútov sú informatívne.
- Fixné páry môžu obsahovať nerelevantné alebo šumové kombinácie, čo znižuje kvalitu modelu.
- Manuálne určovanie závislostí sa stáva nepraktickým pri vysokorozmerných údajoch.

Na odstránenie týchto problémov bol navrhnutý automatický výber párov na základe miery vzájomnej informácie (mutual information, MI).

Výber prebieha nasledovným spôsobom: pre každú dvojicu atribútov (*i*, *j*) sa vypočíta vzájomná informácia MI(*i*, *j*) podľa vzorca:

$$\mathbf{MI(i,j)} = \sum_{x_i, x_j} \boldsymbol{p}(\boldsymbol{x_i}, \boldsymbol{x_j}) \log_e \left(\frac{\boldsymbol{p}(\boldsymbol{x_i}, \boldsymbol{x_j})}{\boldsymbol{p}(\boldsymbol{x_i})\boldsymbol{p}(\boldsymbol{x_j})} \right)$$

Kde:

$\boldsymbol{p}(\boldsymbol{x_i}, \boldsymbol{x_j})$ je empirická spoločná pravdepodobnosť hodnôt $\boldsymbol{x_i}$ a $\boldsymbol{x_j}$,

$\boldsymbol{p}(\boldsymbol{x_i})$ *a* $\boldsymbol{p}(\boldsymbol{x_j})$ sú marginálne pravdepodobnosti hodnôt $\boldsymbol{x_i}$ a $\boldsymbol{x_j}$ samostatne.

Následne sa vyberajú iba tie dvojice (i, j), pre ktoré platí:

$$\mathbf{MI}(\boldsymbol{i}, \boldsymbol{j}) > \boldsymbol{\varepsilon}$$

kde $\boldsymbol{\varepsilon}$ je prahová hodnota pre informatívnosť (napr. ε=0,05).

Významnými prínosmi tohto prístupu sú redukcia šumu ponechávaním len relevantných závislostí, zníženie výpočtovej náročnosti v dôsledku menšieho počtu párov a adaptabilita umožňujúca dynamickú optimalizáciu výberu podľa konkrétneho datasetu.

Príklad dynamického výberu párov pomocou mutual information

Tabuľka 14 Marginálne rozdelenia T, Q, P a C po aktualizácii vzorky

Atribút	Hodnoty	Počty	$\boldsymbol{P}(\boldsymbol{i} = \boldsymbol{x})$
T - čas	K = krátky, S = stredný, D = dlhý	3 / 3 / 3	1/3 každá
Q - kvalita	V = vysoká, S = stredná, N = nízka	3 / 3 / 3	1/3 každá

P - prístup	F = priateľský, N = neutrálne, R = nezdvorilý	4 / 3 / 2	4/9 / 3/9 / 2/9
C - zložitosť	J = jednoduchý, S = stredný, Z = zložitý	3 / 3 / 3	1/3 každá

Krok 1. Spoločná kontingenčná tabuľka pre *T* × *Q*
zachytáva empirické počty všetkých kombinácií hodnôt dvoch atribútov:

Tabuľka 15 Spoločné a marginálne rozdelenia hodnôt T a Q

T \ Q	**V**	**S**	**N**	$\boldsymbol{P(T)}$
K	1	1	1	3/9
S	1	1	1	3/9
D	1	1	1	3/9
$\boldsymbol{P(Q)}$	3/9	3/9	3/9	1

Kde

- Každá vnútorná bunka (*t,q*) uvádza, koľkokrát sa v dátach súčasne vyskytol konkrétny pár hodnôt *T* a *Q*.
- Pravý okraj je marginálna frekvencia príslušnej hodnoty *T* (súčet riadku / n)
- Spodný okraj je marginála pre hodnotu *Q* (súčet stĺpca / n)

Krok 2. Výpočet jednotlivých členov MI
Pre každú bunku platí

$$\boldsymbol{p(t,q)} = \frac{1}{9}$$
$$\boldsymbol{p(t)p(q)} = \frac{3}{9} \times \frac{3}{9} = \frac{1}{9}$$
$$\mathbf{log}_e\left(\frac{\boldsymbol{p(t,q)}}{\boldsymbol{p(t)p(q)}}\right) = \mathbf{log}_e\mathbf{1} = \mathbf{0}$$

Krok 3. Výpočet mutual information

$$\mathbf{MI(T,Q)} = \sum_{\boldsymbol{t,q}} \boldsymbol{p(t,q)}\,\mathbf{log}_e\left(\frac{\boldsymbol{p(t,q)}}{\boldsymbol{p(t)p(q)}}\right) = \mathbf{0}$$

Význam nulovej vzájomnej informácie

- Hodnota MI = 0 znamená, že atribúty T (dĺžka čakania) a Q (kvalita riešenia) sú v aktuálnej vzorke empiricky nezávislé.
- Znalosť konkrétnej dĺžky čakania neznižuje neurčitosť o kvalite riešenia – a naopak.

- Model teda z pohľadu čistej korelácie nezíska žiadnu prediktívnu výhodu sledovaním tejto dvojice; môže ju bezpečne ponechať ako podmienečne nezávislú, kým nové dáta nezdvihnú hodnotu MI nad prah ε.

Aj keď dvojica T × Q nepreukázala žiadnu vzájomnú informáciu, rovnakým postupom sme analyzovali všetky ostatné kombinácie atribútov v datasete. Niektoré páry vykázali nenulové, ba dokonca výrazné hodnoty MI, čím signalizujú, že sú medzi nimi prítomné štatisticky relevantné závislosti, ktoré môže model využiť.

Tabuľka 16 Výsledky testu informatívnosti (MI)

Pár	**MI(i,j)**	**Zaradenie *ε > 0,1***
Q × P	0,637	Áno
P × C	0,424	Áno
T × C	0,462	Áno
Q × C	0,308	Áno
T × P	0,116	Áno
T × Q	0,000	Nie

Páry so zaradeniem „Áno“ prekročili prah ε a budú vstupovať do modulu Interpolácie párových pravdepodobností; pre každú z týchto dvojíc sa následne vypočítajú párové váhy podľa rovnice 2.1.1.4. Nezaradená dvojica T × Q zostáva v modeli ako podmienečne nezávislá, kým nové údaje nezvýšia jej mieru MI nad prahovú úroveň. Týmto dynamickým výberom sa model sústreďuje len na skutočne informatívne interakcie a vyhýba sa zbytočnému šumu.

2.1.2.2 Automatická optimalizácia hyperparametrov pomocou krížovej validácie

V pôvodnom modeli podľa [Maimon2001] boli hodnoty hyperparametrov α, β, γ a λ volené fixne bez ohľadu na charakter údajov, čo obmedzovalo adaptabilitu modelu, preto bol v navrhovanom riešení implementovaný mechanizmus automatickej optimalizácie hyperparametrov založený na mriežkovom vyhľadávaní (grid search) v kombinácii s 5-násobnou krížovou validáciou (5-fold cross-validation), kde sa pre každý kandidátsky súbor parametrov náhodne permutované údaje rozdelili na päť častí, pričom model bol opakovane trénovaný na štyroch častiach a vyhodnocovaný na jednej validačnej množine na základe priemernej spoľahlivosti, aby sa zabezpečilo optimálne prispôsobenie modelu konkrétnemu datasetu a minimalizovali sa riziká spôsobené pevne zvolenými hodnotami.

Pre každý kandidátsky súbor hodnôt (*α,β,γ,λ*) sa postupuje nasledovne:

Krok 1. Údaje sa náhodne permutujú a rozdelia na 5 častí.

Krok 2. Pre každú fold kombináciu:

2A. Model sa trénuje na 4 častiach (trénovacia množina).

2B. Hodnotí sa priemerná presnosť na 1 časti (validačná množina) pomocou:

$$\text{AvgAccuracy} = \frac{1}{N}\sum_{i=1}^{N} I(\hat{y}_i = y_i),$$

Kde:

- $I(\hat{y}_i = y_i)$ je indikátor správnej predikcie,
- $(\hat{y}_i)$ je predikovaná trieda pre i-tu vzorku,
- y_i je skutočná trieda pre i-tu vzorku,
- N je počet vzoriek vo validačnej množine.

Krok 3. Po prebehnutí všetkých 5 foldov sa spočíta priemerná validačná spoľahlivosť pre danú kombináciu parametrov.

Krok 4. Vyberie sa tá kombinácia (*α,β,γ,λ*), ktorá dosiahla najvyššiu priemernú validačnú spoľahlivosť.

Tabuľka 17 Porovnanie fixných a automaticky optimalizovaných hyperparametrov

Aspekt	**Výber fixných hodnôt**	**Automatická optimalizácia (grid search + 5-fold CV)**
Adaptabilita k dátam	Nízka	Vysoká
Presnosť modelu	Môže byť výrazne nižšia	Zvyšuje sa optimalizáciou na dáta
Náročnosť výpočtu	Nízka	Vyššia (viac tréningových cyklov)
Robustnosť na nové datasety	Slabá	Silná
Riziko pretrénovania	Nízke (ak zvolené rozumne)	Kontrolované cez cross-validation

2.1.2.3 Hodnotenie spoľahlivosti pomocou viacerých režimov

Pôvodný prístup podľa [Maimon2001] využíval fixný model na hodnotenie spoľahlivosti rozhodnutí bez dodatočného prispôsobenia v priebehu spracovania údajov. Tento prístup je však v prostredí online učenia limitujúci, najmä v záverečných častiach datasetu, kde sa distribúcia údajov môže meniť a pevný model nemusí zachytávať aktuálne trendy.

Na riešenie týchto obmedzení boli navrhnuté a implementované tri rôzne režimy hodnotenia spoľahlivosti(Obrázok 3):

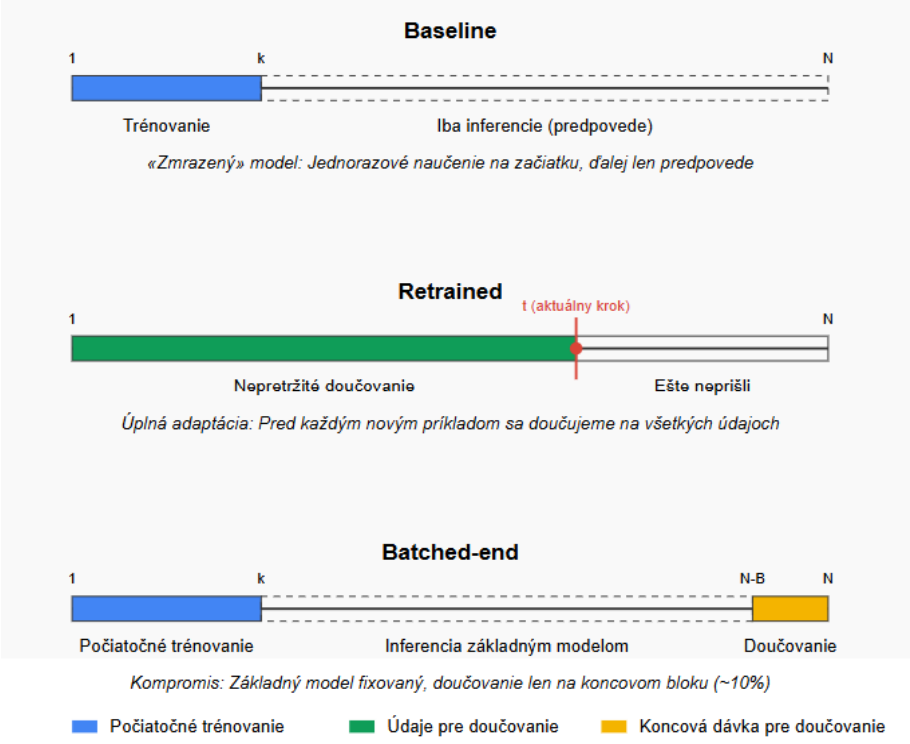

Obrázok 3 Porovnanie stratégií tréningu a inferencie pri hodnotení spoľahlivosti: baseline, retrained a batched-end

Baseline reliability

Režim baseline reliability vyhodnocuje spoľahlivosť rozhodnutí pomocou pôvodne natrénovaného modelu bez ďalšej aktualizácie. Tento prístup je výpočtovo najefektívnejší, no jeho presnosť môže byť znížená v prípadoch, keď sa distribúcia údajov počas spracovania významne mení. Spoľahlivosť v režime baseline reliability sa počíta podľa vzorca definovaného v časti 2.1.1.5.

Retrained reliability

Režim retrained reliability poskytuje najvyššiu presnosť odhadu spoľahlivosti rozhodnutí, pretože pred každou predikciou sa model opätovne trénuje na všetkých doteraz

dostupných údajoch. Tento prístup umožňuje neustálu adaptáciu na meniace sa charakteristiky dát, no zároveň prináša výrazne vyššiu výpočtovú náročnosť, ktorá môže obmedzovať jeho využiteľnosť v reálnom čase.

Batched-end reliability

Režim batched-end reliability predstavuje vyvážený kompromis medzi presnosťou a výpočtovou efektivitou. Spoľahlivosť sa v tomto prípade pre posledné vzorky v datasete hodnotí pomocou dočasne pretrénovaného modelu, ktorý je trénovaný iba na najnovších údajoch. Tento prístup zabezpečuje lepšie prispôsobenie dynamickým zmenám dát pri zachovaní primeranej rýchlosti spracovania, vďaka čomu je obzvlášť vhodný pre praktické online aplikácie.

Výsledné porovnanie jednotlivých režimov hodnotenia spoľahlivosti je uvedené v nasledujúcej tabuľke:

Tabuľka 18 Porovnanie režimov hodnotenia spoľahlivosti modelu

Kritérium	Baseline reliability	Retrained reliability	Batched-end reliability
Presnosť odhadu	Nízka až stredná	Vysoká	Stredná až vysoká
Výpočtová náročnosť	Nízka	Veľmi vysoká	Stredná
Prispôsobenie zmene údajov	Slabé	Výborné	Dobré
Vhodnosť pre online učenie	Vysoká	Obmedzená (kvôli náročnosti)	Vysoká
Riziko pretrénovania	Nízke	Stredné	Nízke

Z tabuľky vyplýva, že režim retrained reliability ponúka najvyššiu presnosť, avšak jeho použitie v online scenároch môže byť kvôli náročnosti obmedzené. Naopak, režim batched-end reliability predstavuje efektívny kompromis medzi presnosťou a rýchlosťou, vďaka čomu sa javí ako najvhodnejšie riešenie pre praktické aplikácie online učenia.

2.2 Záver

Táto kapitola analyzovala existujúci váhový fuzzy model navrhnutý Maimonom et al. [Maimon2001] a predstavila rozšírenia a vylepšenia zamerané na zvýšenie praktickej použiteľnosti modelu v reálnych podmienkach.

Pôvodný model ponúka robustný rámec na kombinovanie informatívnych príspevkov atribútov prostredníctvom interpolácie pravdepodobností a výpočtu fuzzy spoľahlivosti

rozhodnutia, pričom je vhodný pre dáta vykazujúce neurčitosť a nespoľahlivosť. Napriek tomu vykazoval viaceré praktické obmedzenia, vrátane potreby manuálneho výberu závislých párov atribútov, používania fixných hyperparametrov bez adaptácie na dáta a absencie mechanizmu na hodnotenie spoľahlivosti záverečných údajov.

Implementované rozšírenia tieto nedostatky eliminovali. Dynamický výber párov atribútov na základe miery vzájomnej informácie zvýšil relevanciu modelu. Automatická optimalizácia hyperparametrov pomocou mriežkového vyhľadávania a krížovej validácie umožnila prispôsobiť model charakteristikám konkrétnych datasetov. Zavedenie režimu batched-end reliability zabezpečilo korektné hodnotenie spoľahlivosti aj v záverečných fázach online učenia. Flexibilita výberu režimu hodnotenia (baseline, retrained, batched) zároveň umožnila podrobnejšiu analýzu správania modelu v rôznych scenároch.

Porovnanie pôvodného modelu a navrhnutého riešenia je zhrnuté v Tabuľka 19:

Tabuľka 19 Porovnanie pôvodného modelu a navrhnutého riešenia

Kritérium	**Pôvodný model [Maimon2001]**	**Navrhnuté riešenie**
Výber párov atribútov	Fixný, manuálny	Dynamický na základe MI
Ladenie hyperparametrov	Fixné hodnoty	Automatický grid search
Robustnosť na poradie údajov	Nízka	Vyššia
Hodnotenie spoľahlivosti koncových údajov	Nie	Áno (batched-end)
Adaptabilita na rôzne datasety	Obmedzená	Vysoká

Porovnanie potvrdzuje, že navrhované rozšírenia zvyšujú spoľahlivosť, adaptabilitu a praktickú využiteľnosť modelu, pričom zachovávajú jeho pôvodné silné stránky

3 TEORETICKÉ ZÁKLADY ANALÝZY SPOĽAHLIVOSTI DÁT

3.1 Návrh a architektúra riešenia

Cieľom praktickej časti tejto práce bolo navrhnúť a implementovať softvérové riešenie na hodnotenie spoľahlivosti predikcie v rozhodovacích modeloch pomocou váhového fuzzy prístupu, ktorý bol podrobne popísaný v teoretickej časti (kapitola 2). Navrhnuté riešenie reflektuje požiadavky na vysokú adaptabilitu na rôzne datasety, podporu viacerých režimov hodnotenia spoľahlivosti a jednoduchú rozšíriteľnosť.

Na základe funkčných požiadaviek bola definovaná nasledujúca základná funkcionalita systému:

- načítanie trénovacích a testovacích dát zo súboru;
- učenie váhového fuzzy modelu pomocou trénovacích dát;
- interpolácia pravdepodobností tried na základe naučených váhov;
- klasifikácia prípadov v testovacích dátach;
- výpočet fuzzy miery spoľahlivosti rozhodnutí v rôznych režimoch (baseline, retrained, batched-end);
- generovanie a zápis výsledkov klasifikácie a hodnotenia spoľahlivosti do CSV súborov.

Väčšina implementovanej funkcionality sa sústreďuje na oblasť učenia váhového fuzzy modelu a hodnotenia spoľahlivosti predikcie. Na základe tejto skutočnosti bolo rozhodnuté, že vyvinutý softvérový nástroj ponesie označenie WaFRE (Weighted Fuzzy Reliability Evaluation).

3.2 Hlavné komponenty systému

Jadro systému WaFRE – Weighted Fuzzy Reliability Evaluation bolo implementované v jazyku C++ s dôrazom na modulárnosť, rozšíriteľnosť a jednoduchú údržbu. WaFRE pozostáva z viacerých samostatných komponentov, z ktorých každý je zodpovedný za špecifickú časť funkcionality. Ich vzájomné prepojenie vytvára logicky ucelený systém podporujúci hodnotenie spoľahlivosti rozhodovacích modelov.

Základné komponenty core modulu sú nasledovné:

- **FuzzyReliabilityModel**
  Hlavná trieda implementujúca váhový fuzzy model. Obsahuje metódy na učenie

modelu zo vstupných trénovacích dát, výpočet váh, interpoláciu pravdepodobností tried a klasifikáciu prípadov.

- **ReliabilityUtils**
  Pomocný modul poskytujúci funkcie pre výpočet fuzzy miery spoľahlivosti v rôznych režimoch: baseline (základný), retrained (s dodatočným učením) a batched-end (hodnotenie posledných prípadov).
- **OutputCSV**
  Komponent určený na generovanie a zápis výstupov do CSV formátu. Umožňuje automatizované ukladanie výsledkov klasifikácie a spoľahlivosti pre ďalšiu analýzu.
- **Config**
  Trieda zabezpečujúca konfiguráciu systému. Umožňuje automatickú konfiguráciu atribútov, tried, domén hodnôt a závislých párov bez potreby ručných zmien v kóde. Podporuje viacero datasetov vrátane Car Evaluation, Balance Scale.

Riadenie aplikácie a spúšťanie jednotlivých komponentov zabezpečuje hlavný súbor Main.cpp, ktorý načítava konfiguráciu, inicializuje model, načíta dáta, vykoná klasifikáciu, výpočet spoľahlivosti a zápis výsledkov.

3.2.1 FuzzyReliabilityModel

Implementačný popis systému WaFRE sa začína triedou FuzzyReliabilityModel (Obrázok 4), ktorá zabezpečuje hlavnú funkcionalitu váhového fuzzy modelovania.

Trieda riadi proces učenia modelu, vykonáva interpoláciu pravdepodobností tried, klasifikáciu prípadov a výpočet fuzzy miery spoľahlivosti rozhodnutí.

Zároveň poskytuje metódy na analýzu váhových príspevkov a identifikáciu závislých párov atribútov na základe vzájomnej informácie.

```
FuzzyReliabilityModel
-int numInputs
-int numClasses
-double alpha
-double beta
-double gamma
-double lambda
-vector<pair<int,int>> dependentPairs
-int totalExamples
-vector<int> targetCounts
-vector<vector<vector<int>>> conditionalCounts
-vector<vector<vector<vector<int>>>> pairCounts
-vector<double> priorProbs
-vector<vector<vector<double>>> condProbs
-vector<vector<vector<vector<double>>>> pairProbs
-vector<double> bias
-vector<vector<vector<double>>> singleWeights
-vector<vector<vector<vector<double>>>> pairWeights
+FuzzyReliabilityModel(vector<int>, vector<pair<int,int>>, int, double, double, double, double)
+void TrainOnline(vector<vector<int>>, vector<int>)
+void UpdateOnline(vector<int>, int)
+int Classify(vector<int>) const
+double EvaluateReliability(vector<int>, int) const
+double getSingleWeight(int, int, int) const
+double getPairWeight(int, int, int, int, int) const
+vector<int> getDomainSizes() const
+vector<pair<int,int>> getDependentPairs() const
+int getNumClasses() const
+double getAlpha() const
+double getBeta() const
+double getGamma() const
+double getLambda() const
+vector<ConnectionWeight> topSingleWeights(int, vector<string>, vector<vector<string>>, vector<string>) const
+vector<PairConnectionWeight> topPairWeights(int, vector<string>, vector<vector<string>>, vector<string>) const
+vector<BatchInfo> lowReliabilityBatches(vector<vector<int>>, vector<int>, double) const
+static vector<pair<int,int>> computeDependentPairs(vector<vector<int>>, double)
```

Obrázok 4 Štruktúra triedy FuzzyReliabilityModel v systéme WaFRE

Podrobný popis verejných metód triedy FuzzyReliabilityModel:

- FuzzyReliabilityModel() – konštruktor inicializuje interné štruktúry modelu podľa veľkostí domén vstupných atribútov, závislých párov, počtu tried a zadaných parametrov alfa, beta, gama a lambda. Pripraví všetky počítané váhy a pravdepodobnosti na výpočet fuzzy spoľahlivosti.
- TrainOnline() – prechádza všetky trénovacie dáta po jednom a postupne volá UpdateOnline na aktualizáciu váh a pravdepodobností.
- UpdateOnline() – pridáva jeden nový prípad do štatistík modelu, aktualizuje počty výskytov a následne prepočíta všetky pravdepodobnosti a váhy vrátane bias, singleWeights a pairWeights.
- Classify() – klasifikuje zadaný prípad podľa súčasných váh modelu. Vypočíta skóre pre každú triedu a vráti index triedy s najvyšším skóre (2.1.1.5).
- EvaluateReliability() – vypočíta fuzzy mieru spoľahlivosti pre zadaný prípad a očakávanú triedu podľa exponenciálnej funkcie založenej na rozdiele skóre.
- getSingleWeight(i, x, j) – vráti hodnotu váhy pre atribút *i*, hodnotu *x* a triedu *j* (2.1.1.3) .
- getPairWeight(i1, x1, i2, x2, j) – vráti hodnotu párovej váhy medzi atribútmi *i1*, *i2* s hodnotami *x1*, *x2* pre triedu *j (2.1.1.4)*.
- getDomainSizes() – vráti zoznam veľkostí domén všetkých atribútov modelu.

- getDependentPairs() – vráti zoznam všetkých párov závislých atribútov použitých v druhom váhovom slote modelu.
- getNumClasses() – vráti počet tried cieľovej premenné.
- getAlpha() – vráti hodnotu parametra *α* používaného pri interpolácii apriórnych pravdepodobností.
- getBeta() – vráti hodnotu parametra *β* používaného pri interpolácii podmienených pravdepodobností.
- getGamma() – vráti hodnotu parametra *γ* pre interpoláciu párových podmienených pravdepodobností.
- getLambda() – vráti hodnotu parametra *λ* pre výpočet miery spoľahlivosti.
- topSingleWeights() – vráti zoznam *k* najväčších jednoduchých váh v modeli spolu s interpretáciou, vhodné na analýzu najvýznamnejších vstupov.
- topPairWeights() – vráti zoznam *k* najväčších párových váh s interpretáciou, ktoré poukazujú na silné interakcie medzi dvojicami atribútov.
- lowReliabilityBatches() – identifikuje a vráti zoznam prípadov, ktorých spoľahlivosť je pod zadaným prahom. Výstup obsahuje aj pôvodné atribúty a predikované hodnoty.
- computeDependentPairs() – vypočíta závislé páry atribútov na základe vzájomnej informácie a vráti len tie, ktoré prekračujú daný prah (2.1.2.1).

3.2.2 FuzzyReliabilityModel

Implementačný popis systému WaFRE pokračuje pomocným modulom ReliabilityUtils (Obrázok 5), ktorý zabezpečuje výpočet fuzzy miery spoľahlivosti v rôznych režimoch.

Trieda poskytuje metódy na základný výpočet spoľahlivosti, ako aj pokročilé techniky založené na opätovnom učení modelu a čiastočnej rekvalifikácii modelu na podmnožine posledných prípadov, čím umožňuje flexibilnú analýzu správania modelu v rôznych scenároch.

Aby bolo možné jednoducho a bezpečne prepínať medzi týmito režimami bez rizika chýb spôsobených nesprávnymi číselnými kódmi alebo reťazcami, bol zavedený enum ReliabilityMode.

Tento enum definuje explicitné a čitateľné hodnoty režimov:

- Base – základné hodnotenie na existujúcom modeli.
- Retrained – hodnotenie po opätovnom učení na všetkých predchádzajúcich dátach.

- BatchedEnd – výpočet fuzzy spoľahlivosti pomocou modelu, ktorý je natrénovaný výhradne na poslednej množine prípadov, bez zohľadnenia predchádzajúcich dát.

Použitím enumu sa zvyšuje bezpečnosť typov, čitateľnosť kódu a znižuje sa riziko nekonzistentných volaní funkcií.

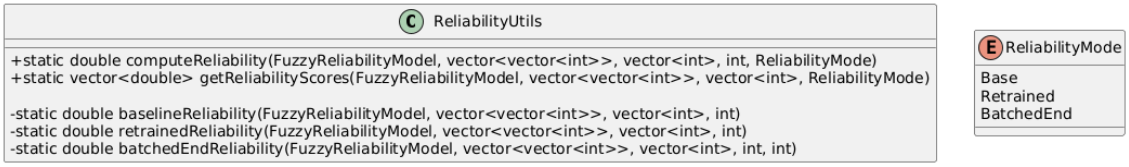

Obrázok 5 Modul ReliabilityUtils a režimy výpočtu fuzzy spoľahlivosti

Podrobný popis verejných metód triedy ReliabilityUtils:

- computeReliability() – univerzálna obálka, ktorá podľa režimu volá príslušný spôsob výpočtu spoľahlivosti pre daný prípad;
- getReliabilityScores() – vráti vektor spoľahlivostí pre všetky prípady v dátovej množine podľa zvoleného režimu;
- baselineReliability() – vypočíta základnú fuzzy mieru spoľahlivosti pomocou aktuálneho modelu bez ďalšieho učenia;
- retrainedReliability() – vytvorí nový model, ktorý sa naučí na všetkých predchádzajúcich prípadoch, a na jeho základe vyhodnotí spoľahlivosť aktuálneho prípadu;
- batchedEndReliability() – pre posledné prípady vytvorí nový model trénovaný na obmedzenej vzorke najnovších dát a na jeho základe vyhodnotí spoľahlivosť aktuálneho prípadu.

3.2.3 OutputCSV

Implementačný popis systému WaFRE pokračuje pomocným modulom OutputCSV (Obrázok 6), ktorý zabezpečuje systematický zápis výsledkov modelu a analytických údajov do CSV formátu. Trieda poskytuje metódy na generovanie výstupných tabuliek pre schému atribútov, kódovanie hodnôt, najvýznamnejšie váhové príspevky, identifikáciu nespoľahlivých prípadov a porovnanie spoľahlivosti naprieč rôznymi režimami učenia.

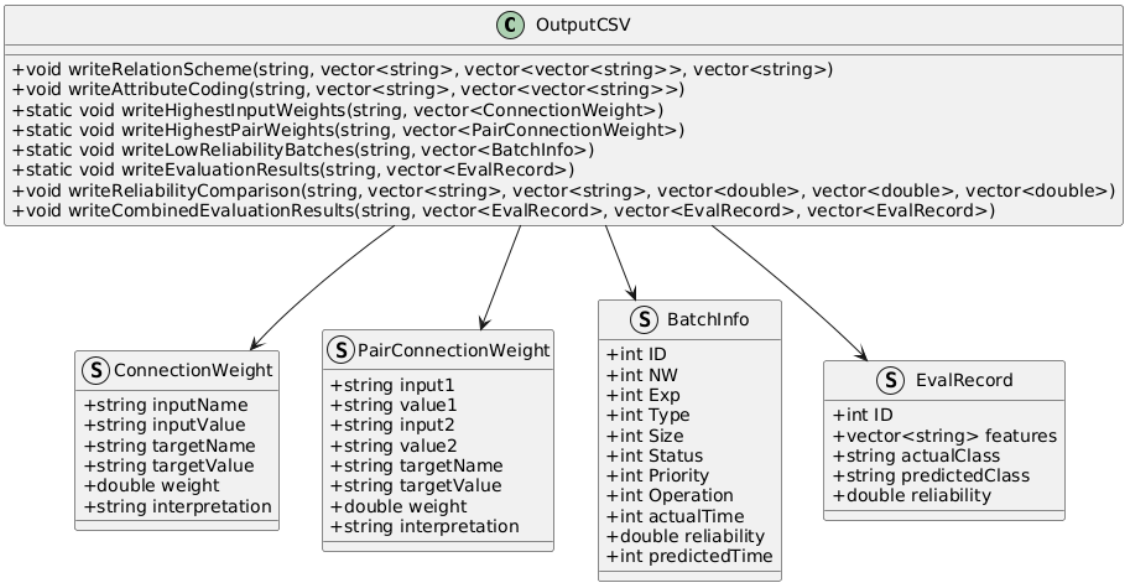

Obrázok 6 Modul OutputCSV a štruktúra výstupných analytických údajov

V triede OutputCSV sa využívajú pomocné dátové štruktúry, na organizáciu informácií potrebných pre výstupné CSV súbory:

• ConnectionWeight – štruktúra reprezentujúca jednotlivé váhové spojenie medzi hodnotou atribútu a cieľovou triedou. Obsahuje názvy atribútov, konkrétne hodnoty, cieľovú triedu, váhu spojenia a interpretačný text.

• PairConnectionWeight – štruktúra zachytávajúca párové váhové spojenia medzi dvoma vstupnými atribútmi a cieľovou triedou. Obsahuje názvy a hodnoty oboch atribútov, cieľovú triedu, váhu interakcie a jej interpretáciu.

• BatchInfo – štruktúra opisujúca vlastnosti jednotlivých prípadov s nízkou spoľahlivosťou. Zahŕňa identifikátory prípadu a jeho atribútov, vypočítanú spoľahlivosť a predikovanú hodnotu.

• EvalRecord – štruktúra uchovávajúca výsledky hodnotenia modelu pre konkrétny prípad, vrátane všetkých hodnôt atribútov, skutočnej a predikovanej triedy a spoľahlivosti.

Podrobný popis verejných metód triedy OutputCSV:

• writeRelationScheme() – zapíše schému atribútov vrátane ich domén a označenia typu (vstupný alebo cieľový atribút).

• writeAttributeCoding() – vytvorí kódovaciu tabuľku atribútov, zobrazujúcu všetky možné hodnoty jednotlivých premenných.

• writeHighestInputWeights() – zapíše zoznam *k* najväčších váhových príspevkov medzi jednotlivými atribútmi a triedami vrátane interpretácie.

• writeHighestPairWeights() – uloží najvýznamnejšie váhové interakcie medzi dvojicami atribútov a ich vplyv na cieľové triedy.

• writeLowReliabilityBatches() – exportuje zoznam prípadov so spoľahlivosťou pod zadaným prahom vrátane základných atribútov a predikcie.

• writeEvaluationResults() – zaznamenáva jednotlivé hodnoty atribútov, skutočné a predikované triedy a vypočítanú fuzzy spoľahlivosť v percentách.

• writeReliabilityComparison() – vytvorí porovnanie výsledkov spoľahlivosti medzi základným modelom, modelom po opätovnom učení a modelom učeným na posledných prípadoch.

• writeCombinedEvaluationResults() – generuje zjednotený súbor výsledkov, obsahujúci porovnanie všetkých troch stratégií (Base, Retrained, BatchedEnd) pre každý prípad.

3.2.4 Config

Implementačný popis systému WaFRE pokračuje pomocnou konfiguráciou Config ktorá zabezpečuje automatizovanú inicializáciu parametrov modelu na základe výberu datasetu.

Tento modul uľahčuje nahrávanie atribútov, hodnôt domén, názvov tried, mapovania kategórií a závislých párov bez potreby manuálnych zmien v kóde.

Jeho hlavnou úlohou je pripraviť kompletné nastavenie pre učenie modelu a zabezpečiť konzistenciu vstupných údajov.

Podrobný popis funkcionality:

getConfig(choice, filename, numAttributes, numClasses, attributeMaps, attributeVals, attributeNames, classMap, classVals, domainSizes, dependentPairs)

Na základe hodnoty choice inicializuje všetky potrebné parametre datasetu:

- nastaví cestu k súboru s dátami (filename);
- definuje počet atribútov (numAttributes) a počet tried (numClasses);
- vytvorí mapovania hodnôt atribútov a tried na číselné hodnoty;
- naplní zoznam názvov atribútov a možných hodnôt pre každý atribút (attributeVals);
- naplní zoznam hodnôt cieľovej premennej (classVals);
- určí veľkosti domén pre každý atribút (domainSizes);
- špecifikuje páry závislých atribútov (dependentPairs) na použitie v párových pravdepodobnostiach modelu.

Ak je zadaná neplatná voľba datasetu, funkcia vyhodí výnimku std::invalid_argument.

3.2.5 Riadiaci tok systému WaFRE

Implementácia hlavného riadiaceho toku systému WaFRE je sústredená v súbore Main.cpp, ktorý integruje všetky komponenty popísané v predchádzajúcich podkapitolách 3.2.1 až 3.2.4. Tento súbor riadi celý životný cyklus systému – od výberu scenára a datasetu, cez inicializáciu modelu, trénovanie, až po vyhodnotenie a export výsledkov.

Struktúra main.cpp je modulárna a zodpovedá nasledujúcim etapám:

Krok 1. Výber scenára a datasetu

1A. Scenár učenia – buď originálny (so statickými pármi a fixnými parametrami), alebo vylepšený (s dynamickým výpočtom závislostí a optimalizáciou hyperparametrov). Podrobnosti o výpočte závislých párov sú uvedené v časti 3.2.1, konkrétne v metóde compute Dependent Pairs().

1B. Dataset – podporované sú datasety Balance Scale a Car Evaluation, ktorých konfigurácia je realizovaná pomocou funkcie getConfig() (3.2.4).

Krok 2. Načítanie dát a predspracovanie

Načítanie dát zabezpečuje funkcia loadData(), ktorá prevádza hodnoty do číselnej reprezentácie pomocou máp pripravených v konfiguračnom kroku. Pozícia cieľovej triedy závisí od zvoleného datasetu. Voliteľne je možné trénovacie dáta zamiešať shuffleAllData().

Krok 3. Tréning modelu

Na základe zvoleného scenára sa model FuzzyReliabilityModel natrénuje pomocou metódy TrainOnline(). Ak bol zvolený dynamický režim, pred tréningom sa vykoná optimalizácia parametrov alpha, beta, gamma a lambda cez 5-násobný grid-search gridSearch().

Krok 4. Vyhodnotenie v troch režimoch

Presnosť a spoľahlivosť modelu sa vyhodnocuje pomocou funkcie evaluateAll() v troch režimoch popísaných v časti 3.2.2

Krok 4. Export výsledkov

Všetky výsledky sa automaticky ukladajú do CSV formátu cez metódy modulu OutputCSV (pozri 3.2.3). Vygenerujú sa výstupné tabuľky so schémou atribútov,

váhovými príspevkami, vyhodnotením spoľahlivosti v troch režimoch, ako aj porovnávacie tabuľky.

Celý proces je znázornený na obrázku Diagram aktivity hodnotenia fuzzy modelu spoľahlivosti údajov (Obrázok 7), ktorý sumarizuje kľúčové kroky realizované v main.cpp.

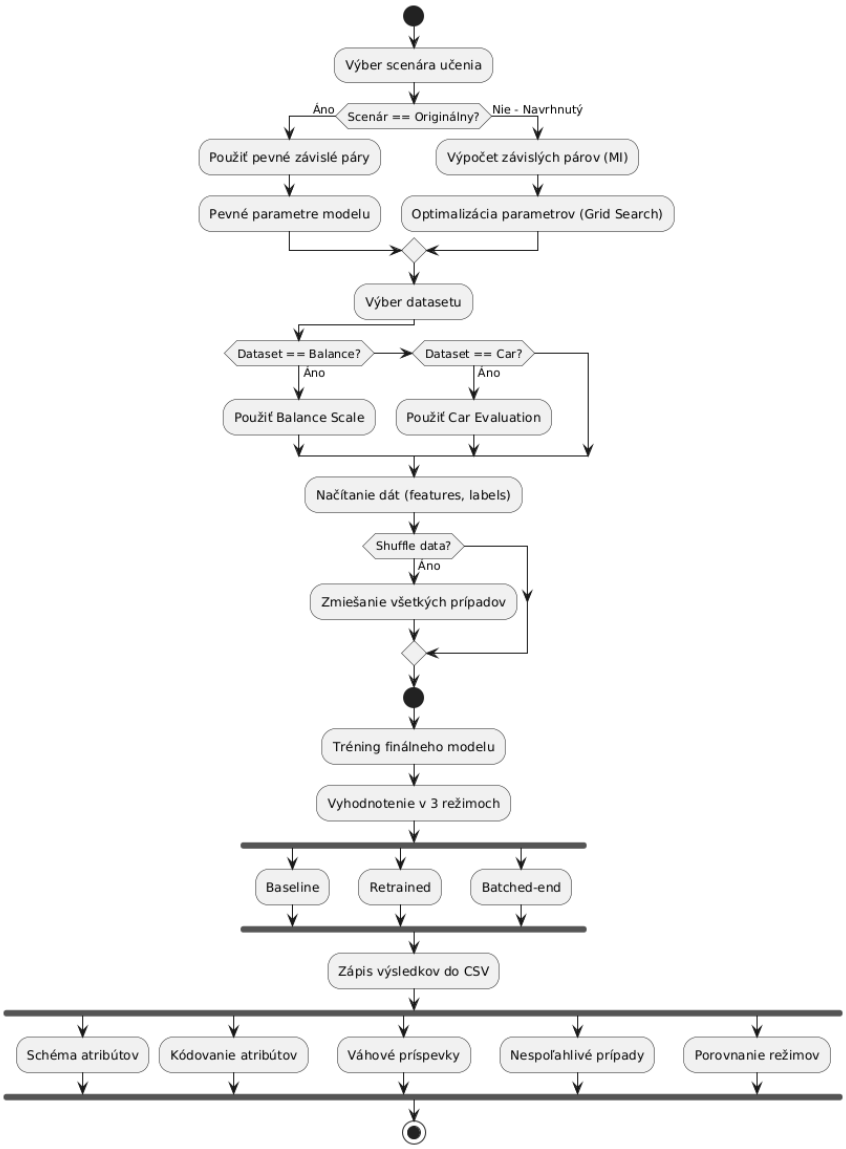

Obrázok 7 Diagram aktivity hodnotenia fuzzy modelu spoľahlivosti údajov

3.3 Používateľské rozhranie a výstupy systému

Táto časť predstavuje spôsob, akým systém WaFRE komunikuje s používateľom počas svojho spustenia, spracovania údajov a následného poskytovania analytických výstupov. Na rozdiel od grafických používateľských rozhraní (GUI), systém funguje ako konzolová aplikácia, pričom interakcia prebieha formou otázok a odpovedí v príkazovom riadku, ako aj automatickým generovaním súborov vo formáte CSV.

Z pohľadu používateľa je dôležité porozumieť, ako prebieha tok výpočtu, aké možnosti konfigurácie sú k dispozícii, aké výstupy systém poskytuje a kde sa dajú nájsť relevantné výsledky. Jasnosť týchto výstupov je zásadná pre správnu interpretáciu spoľahlivosti rozhodnutí a kvality modelu.

V nasledujúcich podkapitolách preto podrobne ukážeme:

- ako vyzerá konzolová komunikácia počas behu systému;
- aké výstupy sú generované do CSV tabuliek na ďalšie spracovanie alebo analýzu v prostredí ako Excel.

Tieto výstupy budú doplnené reálnymi ukážkami a stručným výkladom ich významu pre používateľa.

3.3.1 Konzolový výstup

Konzolový výstup predstavuje základný spôsob interakcie používateľa so systémom WaFRE. Užívateľ komunikuje so systémom v reálnom čase prostredníctvom vstupov (číselných volieb) a zároveň má okamžitý prístup k priebežným informáciám o výpočte.

Základná štruktúra konzolového výstupu obsahuje nasledovné časti (Obrázok 8):

1. Voľba scenára učenia:
   Používateľ rozhoduje, či chce spustiť originálny model (s pevnými závislými pármi a ručne nastavenými parametrami), alebo vylepšený scenár (s dynamickou detekciou závislostí a optimalizáciou hyperparametrov).
2. Voľba datasetu:
   Umožňuje výber jednej z podporovaných množín údajov, čím sa systém prispôsobí špecifickej štruktúre atribútov a tried.
3. Zobrazenie vybraných závislých párov (ak je scenár vylepšený)
4. Dotaz na premiešanie dát
5. Zhrnutie vyhodnotenia modelu v troch režimoch
6. Informácia o zápise výstupov

```
Scenario (0=Original, 1=Enhanced): 1
Select dataset (0=balance, 1=car): 1
Using pairs: (0,1) (2,3)
Grid Search best ACC=0.748406 for (a,b,g,l)=(0.3,0.9,0.9,1)
Shuffle data before train/test? (0=no,1=yes): 0

Enhanced model
Mode          Acc(%)  Avg R
baseline      75.8     1.2
retrained     18.6     1.8
batched-end   78.8     1.1
Base low-confidence -> table5_low_base.csv
Retrained low-confidence -> table5_low_retrained.csv
Batched low-confidence -> table5_low_batched.csv
All CSV tables written
```

Obrázok 8 Konzolový výstup WaFRE

Tento výstup umožňuje používateľovi okamžite porovnať Uvedený výstup umožňuje bezprostredné porovnanie presnosť a priemernú mieru spoľahlivosti naprieč rôznymi režimami a zároveň ho informuje o tom, ktoré výstupné súbory boli vytvorené na ďalšiu analýzu.

3.3.2 Exportované CSV výstupy

Popri konzolovom výstupe systém WaFRE automaticky generuje viaceré CSV súbory, ktoré obsahujú podrobné analytické dáta zo spracovania trénovacích prípadov. Tieto súbory umožňujú ďalšiu analýzu, vizualizáciu a dokumentáciu výsledkov modelu pomocou bežných nástrojov ako Microsoft Excel, LibreOffice alebo programovacích jazykov (napr. Python, R).

Prehľad generovaných CSV výstupov:

1. table1_RelationScheme.csv
   Obsahuje štruktúru vstupných atribútov: názvy, popisy a možné hodnoty každej premennej.
2. table2_AttributeCoding.csv
   Zobrazuje, ako sú jednotlivé hodnoty atribútov zakódované do čísel pre účely učenia modelu.(Tabuľka 25.)
3. table3_topSingleWeights.csv

   Obsahuje zoznam najvýznamnejších jednoduchých váhových príspevkov (single weights) medzi atribútmi a cieľovými triedami vrátane ich interpretácie (

   Tabuľka 20.)

Tabuľka 20 Zoznam najvýznamnejších jednoduchých váhových príspevkov

Input attribute	Value	Target attribute	Connection weight	Interpretation
safety	high	vgood	1.043	i=safety=high ? class=vgood
maint	low	good	0.926	i=maint=low ? class=good
buying	low	good	0.926	i=buying=low ? class=good
lug_boot	big	vgood	0.579	i=lug_boot=big ? class=vgood
safety	med	good	0.495	i=safety=med ? class=good
maint	med	vgood	0.445	i=maint=med ? class=vgood

Napríklad prvý riadok tabuľky označuje, že ak má vstupný atribút safety hodnotu high, pravdepodobnosť priradenia triedy vgood výrazne stúpa. Váha spojenia 1.043 (v logaritmickej mierke) znamená, že existuje veľmi silná pozitívna závislosť medzi stavom „bezpečnosť vozidla je vysoká“ a klasifikáciou vozidla ako veľmi dobrého (*very good*).

Konkrétne, výraz i=safety=high ? class=vgood vyjadruje, že existencia tejto konkrétnej hodnoty vstupu výrazne ovplyvňuje rozhodovanie modelu smerom k triede vgood.

4. table4_topPairWeights.csv
   Zachytáva najvýznamnejšie párové interakcie (pair weights) medzi dvojicami atribútov a ich dopad na predikciu triedy.

Tabuľka 21 Najsilnejšie interakcie atribútových dvojíc podľa váhového príspevku

Input attribute	Value	Input attribute	Value	Target attribute	Connection weight	Interpretation
buying	low	maint	high	vgood	3.787	i=buying=low ∧ maint=high → class=vgood
buying	low	maint	med	good	3.678	i=buying=low ∧ maint=med → class=vgood
buying	med	maint	low	good	3.678	i=buying=med ∧ maint=low → class=vgood

doors	3	persons	more	vgood	3.506	i=doors=3 ∧ persons=more → class=vgood

Napríklad prvý riadok tabuľky označuje, že ak má vstupná inštancia atribúty „nízka kúpna cena“ a zároveň „vysoké náklady na údržbu“, model WaFRE výrazne preferuje klasifikáciu danej inštancie ako vgood (*very good*).

Spojovacia váha 3.787 patrí medzi najvyššie v celom modeli, čo naznačuje, že kombinácia týchto dvoch hodnôt má veľmi vysokú informačnú hodnotu pre rozhodovací proces. Inými slovami, ak sa súčasne vyskytujú hodnoty *buying* = *low* a *maint* = *high*, tak model so značnou istotou priraďuje cieľovú triedu *vgood*.

5. table5_low_base.csv, table5_low_retrained.csv, table5_low_batched.csv

Tieto tabuľky obsahujú zoznam prípadov, ktoré boli modelom klasifikované s nízkou úrovňou spoľahlivosti, pričom hranica pre „nízku spoľahlivosť“ bola nastavená na menej ako 10 %.(Tabuľka 22)

Každá tabuľka zodpovedá inému režimu učenia:

- table5_low_base.csv – nízka spoľahlivosť pri základnom (baseline) modeli bez ďalšieho učenia;
- table5_low_retrained.csv – nízka spoľahlivosť po opätovnom priebežnom učení modelu;
- table5_low_batched.csv – nízka spoľahlivosť pri modeli trénovanom len na poslednej množine prípadov.

Každý záznam v tabuľke zahŕňa:

- ID prípadu – unikátny identifikátor príkladu;
- Hodnoty atribútov – pôvodné hodnoty všetkých vstupných premenných prípadu;
- Skutočnú triedu – reálnu cieľovú hodnotu prípadu;
- Predikovanú triedu – hodnotu predikovanú modelom;
- Spoľahlivosť predikcie – vyjadrenú v percentách.

Tabuľka 22 Porovnanie prípadov s nízkou spoľahlivosťou v rôznych režimoch učenia

ID	Attr1	Attr2	Attr3	Attr4	Attr5	Attr6	Actual	Predicted	Reliability(%)
1101	med	med	2	more	Small	high	unacc	vgood	7.6%

Tieto tabuľky umožňujú:

- Identifikovať kritické prípady, ktoré model klasifikuje s vysokou neistotou;
- Analyzovať vzory v chybných alebo nejasných predikciách;
- Porovnať, ktorý režim učenia poskytuje vyššiu spoľahlivosť v hraničných prípadoch;
- Podporiť rozhodovanie o potrebe zlepšenia modelu alebo doplnení tréningových dát.

Zameranie sa na tieto nízke spoľahlivosti je kľúčové pre praktické nasadenie systému, kde je potrebné minimalizovať riziko nesprávnych alebo neistých rozhodnutí.

6. table6_reliability_comparison.csv

Táto tabuľka sumarizuje porovnanie výsledkov spoľahlivosti pre všetky prípady v dátovej množine naprieč tromi režimami učenia modelu.

Každý riadok tabuľky obsahuje:

- Index prípadu – poradové číslo prípadu v množine.
- Skutočnú triedu (Actual) – reálnu cieľovú hodnotu prípadu.
- Predikovanú triedu (Predicted) – triedu predikovanú základným modelom.
- Spoľahlivosť v baseline režime (BaseReliability) – fuzzy spoľahlivosť výpočítaná na pôvodnom modeli.
- Spoľahlivosť v retrained režime (RetrainedReliability) – spoľahlivosť po opätovnom natrénovaní na všetkých predchádzajúcich prípadoch.
- Spoľahlivosť v batched-end režime (BatchedEndReliability) – spoľahlivosť po natrénovaní modelu na posledných 10 % prípadov.

Tabuľka 23 Porovnanie spoľahlivosti predikcií v režimoch Base, Retrained a BatchedEnd

Index	Actual	Predicted	Base Reliability	Retrained Reliability	BatchedEnd Reliability
1	unacc	unacc	1	1	1

Tabuľka slúži na:

- Komplexné porovnanie správania modelu v rôznych režimoch pre každý jednotlivý prípad.
- Vyhodnotenie stability modelu – napríklad, či sa spoľahlivosť výrazne mení po zmene režimu učenia.
- Identifikáciu prípadov s výraznými odchýlkami v spoľahlivosti medzi režimami.
- Vizualizáciu trendov a slabých miest modelu, napríklad pomocou grafického znázornenia na základe tejto tabuľky.

Údaje v tejto tabuľke môžu byť následne využité na vytváranie grafov, ako napríklad:

- Porovnanie priemernej spoľahlivosti medzi režimami.
- Analýza distribúcie spoľahlivosti pre rôzne triedy.

7. table7_base.csv, table7_retrained.csv, table7_batched.csv, table7_all.csv

Tieto tabuľky detailne zaznamenávajú výsledky hodnotenia modelu na úrovni jednotlivých prípadov pre každý režim učenia.

Štruktúra tabuliek table7_base.csv, table7_retrained.csv, table7_batched.csv:

Každá z týchto troch tabuliek obsahuje nasledovné stĺpce:

- ID – poradové číslo prípadu v množine.
- Hodnoty atribútov (Attr1, Attr2, …) – reálne názvy hodnôt vstupných premenných pre daný prípad.
- Skutočná trieda (Actual) – reálna cieľová trieda prípadu.
- Predikovaná trieda (Predicted) – trieda predikovaná modelom v danom režime.
- Spoľahlivosť v percentách (Reliability(%)) – vypočítaná fuzzy spoľahlivosť predikcie v danom režime.

Každá tabuľka reprezentuje výsledky v konkrétnom režime:

- table7_base.csv – predikcie a spoľahlivosť modelu bez ďalšieho učenia.

- table7_retrained.csv – predikcie po priebežnom opätovnom učení na predchádzajúcich dátach.
- table7_batched.csv – predikcie po mini-tréningu na posledných 10 % prípadov.

Štruktúra tabuľky table7_all.csv:

Tabuľka table7_all.csv je kombinovaná, obsahuje:

- ID, Hodnoty atribútov a Skutočnú triedu.
- Predikovanú triedu v baseline režime (PredictedBase).
- Predikovanú triedu v retrained režime (PredictedRetrained).
- Predikovanú triedu v batched-end režime (PredictedBatched).
- Spoľahlivosť v každom režime – ReliabilityBase(%), ReliabilityRetrained(%), ReliabilityBatched(%).

Význam a využitie tabuliek:

- Umožňujú analyzovať správnosť a istotu predikcií na úrovni jednotlivých prípadov.
- Pomáhajú porovnať výsledky medzi rôznymi režimami učenia pre rovnaké vstupy.
- Identifikujú prípady, kde sa model správa nestabilne alebo nekonzistentne naprieč režimami.
- Slúžia ako vstupný zdroj pre grafickú analýzu spoľahlivosti a správnosti predikcií.
- table7_all.csv umožňuje priamu vizualizáciu rozdielov medzi všetkými režimami na jednom mieste, čo výrazne zjednodušuje hĺbkovú analýzu.

3.4 Záver

Implementácia softvérového riešenia WaFRE splnila všetky ciele stanovené v návrhovej fáze a úspešne integrovala jednotlivé moduly do funkčného a konzistentného systému. Vyvinutý nástroj umožňuje nielen efektívne učenie a hodnotenie váhového fuzzy modelu spoľahlivosti, ale aj flexibilnú konfiguráciu scenárov učenia a výberu datasetu podľa potrieb používateľa. Prostredníctvom prehľadných konzolových hlásení a exportovaných analytických výstupov v CSV formáte systém poskytuje plnohodnotnú podporu pre interpretáciu výsledkov, ich ďalšiu analýzu a adaptáciu modelu na špecifické požiadavky konkrétnej aplikácie.

Realizovaná architektúra zároveň vytvára pevný základ pre budúce rozšírenia a zvyšuje praktickú použiteľnosť riešenia v rôznych doménach, kde je spoľahlivosť rozhodovacích modelov kritickým faktorom.

4 EXPERIMENTÁLNA ANALÝZA A VÝSLEDKY

4.1 Cieľ a metodológia experimentov

Cieľom tejto kapitoly je experimentálne overiť účinnosť navrhnutého vylepšeného váhového fuzzy modelu v porovnaní s pôvodným prístupom predstaveným v práci Maimona et al. [Maimon2001]. Hlavným zámerom je posúdiť, či dynamický výber párov atribútov a automatická optimalizácia hyperparametrov prispievajú k zvýšeniu celkovej spoľahlivosti predikcií.

V rámci experimentov sa analyzuje vplyv vylepšení na kvalitu rozhodnutí v závislosti od typu datasetu a štruktúry údajov. Hodnotenie bude realizované na základe dvoch hlavných metrík:

- Presnosť klasifikácie (accuracy) – podiel správne klasifikovaných príkladov na celkovom počte testovaných príkladov.
- Fuzzy miera spoľahlivosti (R) – kvantifikácia istoty vo výsledné rozhodnutie, založená na rozdiele medzi skóre tried.

Experimentálne testovanie prebehne na dvoch verejne dostupných datasetoch: Car Evaluation a Balance Scale - ktoré boli získané z [UCI]. Pre každý dataset bude porovnaný výkon pôvodného a vylepšeného modelu z hľadiska priemernej presnosti klasifikácie aj distribúcie spoľahlivosti rozhodnutí.

Na analýzu vplyvu rôznych stratégií výpočtu spoľahlivosti sa využijú tri režimy hodnotenia:

- Baseline reliability – výpočet spoľahlivosti bez pretrénovania modelu.
- Retrained reliability – výpočet po opätovnom natrénovaní modelu na predchádzajúcich príkladoch.
- Batched-end reliability – výpočet po dodatočnom natrénovaní modelu na poslednej časti údajov s cieľom zvýšiť presnosť na konci učenia.

Komplexný experimentálny prístup umožní vyhodnotiť robustnosť navrhnutého riešenia v rôznych typoch údajových podmienok a poskytne relevantné porovnanie so štandardným prístupom.

4.2 Opis použitých datasetov

4.2.1 Car Evaluation dataset

4.2.1.1 Parametre a charakteristika datasetu Car Evaluation

Dataset Car Evaluation bol navrhnutý na základe analytickej štúdie procesu posudzovania automobilov podľa viacerých kritérií. Obsahuje 1 728 príkladov, pričom každý príklad obsahuje šesť diskrétnych vstupných atribútov a jednu cieľovú triedu hodnotiacu kvalitu auta.

Popis jednotlivých atribútov a ich domén hodnôt je uvedený v Tabuľka 24.

Tabuľka 24 Štruktúra vstupných a cieľových premenných v datasete Car Evaluation

Názov atribútu	Popis atribútu	Doména hodnôt	Typ
buying	Cena auta	vhigh, high, med, low	Input
maint	Náklady na údržbu	vhigh, high, med, low	Input
doors	Počet dverí	2, 3, 4, 5more	Input
persons	Kapacita osôb	2, 4, more	Input
lug_boot	Veľkosť kufra	small, med, big	Input
safety	Bezpečnosť	low, med, high	Input
class	Hodnotenie auta	unacc, acc, good, vgood	Target

Kódovanie hodnôt jednotlivých atribútov na diskrétne hodnoty je zhrnuté v Tabuľka 25.

Tabuľka 25 Diskrétne kódovanie hodnôt atribútov datasetu Car Evaluation

Atribút	0	1	2	3
buying	vhigh	high	med	low
maint	vhigh	high	med	low
doors	2	3	4	5more

persons	2	4	more	-
lug_boot	small	med	big	-
safety	low	med	high	-

4.2.1.2 Porovnanie výkonnosti modelov

Výsledky experimentu na datasete Car Evaluation sú zhrnuté v Tabuľka 26, kde porovnávame výkonnosť pôvodného modelu a navrhnutého modelu vo všetkých troch režimoch hodnotenia spoľahlivosti.

Tabuľka 26 Výkonnosť modelov vo všetkých režimoch učenia na datasete Car Evaluation

Model	Režim	Presnosť (%)	Priemerná spoľahlivosť (R)
Originálny model	baseline	62.5	1.3
Originálny model	retrained	14.1	1.8
Originálny model	batched-end	63.8	1.3
Navrhnutý model	baseline	75.8	1.2
Navrhnutý model	retrained	18.6	1.8
Navrhnutý model	batched-end	78.8	1.1

Výsledky prezentované vyššie naznačujú, že, navrhnutý model dosahuje vo všetkých režimoch systematicky vyššiu presnosť a zároveň nižšie hodnoty fuzzy miery spoľahlivosti v porovnaní s pôvodným modelom. Zlepšenie je najvýraznejšie v režime batched-end, kde navrhnutý model profituje z dodatočného učenia na záverečných údajoch, čím dosahuje optimálnu kombináciu vysokej presnosti a vysokej istoty rozhodnutí.

4.2.1.3 Vplyv operácie shuffle na presnosť a spoľahlivosť v režime retrained

Predchádzajúce výsledky ukázali, že režim retrained bez náhodného premiešania údajov výrazne znižuje presnosť klasifikácie a spoľahlivosť rozhodnutí. Tento efekt je spôsobený pretrénovaním modelu na neusporiadaných sekvenciách dát, čo vedie k strate generalizačnej schopnosti. Aplikácia shuffle operácie zabezpečila rovnomerné rozloženie príkladov počas učenia, čím sa výkon modelov výrazne zlepšil.

Vývoj presnosti a fuzzy spoľahlivosti pred a po aplikácii shuffle operácie je zobrazený na grafoch Obrázok 9 a Obrázok 10.

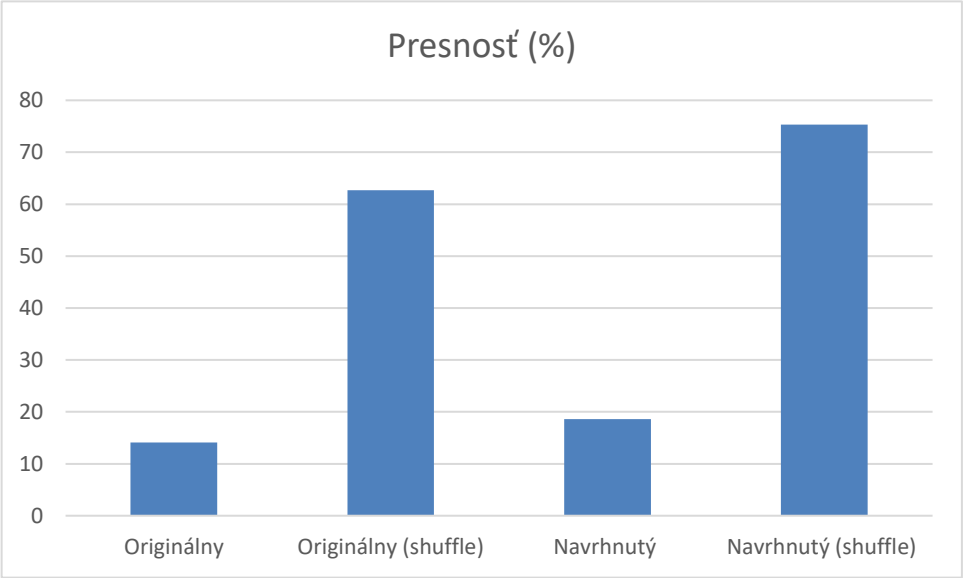

Obrázok 9 Porovnanie presnosti pôvodného a navrhnutého modelu pred a po shuffle

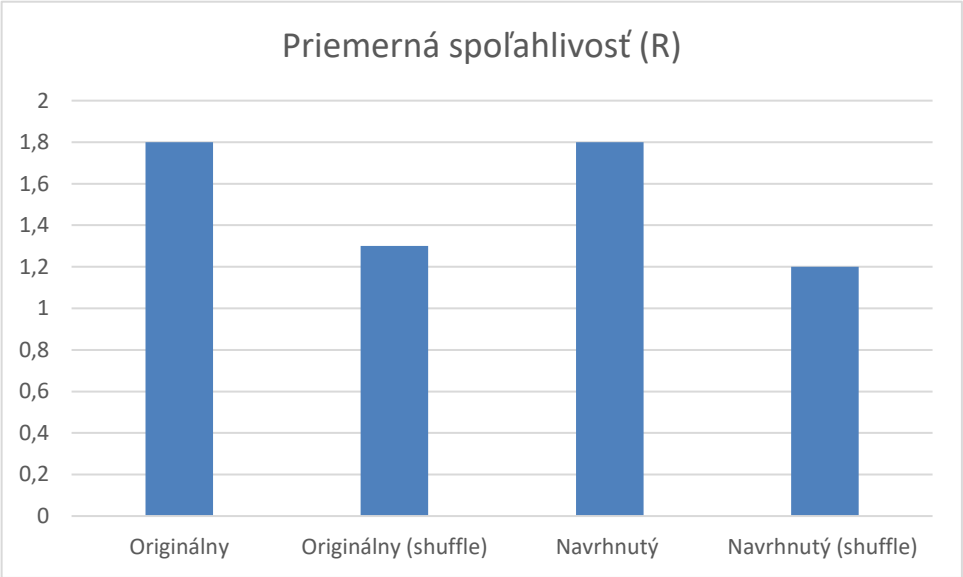

Obrázok 10 Zmena priemernej fuzzy spoľahlivosti modelov po shuffle operácii

Z Obrázku 9 je zrejmé, že presnosť modelov v režime retrained bez shuffle operácie bola výrazne nižšia, pričom po aplikácii shuffle sa presnosť zvýšila. Navrhnutý model dosahuje vyššiu presnosť ako pôvodný model v oboch nastaveniach. Obrázku 10 ukazuje, že aplikácia shuffle operácie viedla aj k zníženiu priemernej fuzzy miery spoľahlivosti (R), čo naznačuje vyššiu istotu rozhodnutí modelov po premiešaní údajov.

Tieto výsledky potvrdzujú, že pre datasety s diskrétnymi a opakujúcimi sa atribútmi je náhodné premiešanie údajov pred učením kritickým krokom na zabezpečenie stabilného a spoľahlivého výkonu v režime retrained.

4.2.1.4 Analýza príkladov s nízkou mierou spoľahlivosti

Pre hlbšie pochopenie správania modelu boli vybrané príklady s najnižšou fuzzy mierou spoľahlivosti (R) v režime Navrhnutý model bez shuffle, batched-end. Tabuľka 27 sumarizuje 10 prípadov s hodnotou spoľahlivosti pod 10 %.

Tabuľka 27 Príklady s extrémne nízkou fuzzy spoľahlivosťou v hraničných prípadoch v datasete Car Evaluation

ID	Attr1	Attr2	Attr3	Attr4	Attr5	Attr6	Actual	Predicted	Reliability (%)
1208	med	low	2	more	small	med	unacc	good	1.0
1532	low	med	2	more	small	med	unacc	good	1.0
1209	med	low	2	more	small	high	unacc	good	1.1
1533	low	med	2	more	small	high	unacc	good	1.1
1199	med	low	2	4	small	med	acc	good	2.3
1226	med	low	3	4	small	med	acc	good	2.3
1523	low	med	2	4	small	med	acc	good	2.3
1550	low	med	3	4	small	med	acc	good	2.3
1640	low	low	2	more	small	med	unacc	acc	2.4
1235	med	low	3	more	small	med	acc	good	2.5

Z analyzovaných výsledkov je možné pozorovať, že všetky vybrané príklady sa vyznačujú veľmi podobným atribútovým profilom — ide prevažne o malé vozidlá s nízkou alebo strednou bezpečnosťou, nižším alebo stredným počtom dverí a obmedzenou veľkosťou batožinového priestoru. Táto konfigurácia vedie k tomu, že rozhodovacie hranice medzi triedami *unacc*, *acc* a *good* sa stávajú veľmi blízkymi alebo sa priamo prekrývajú.

Nízke hodnoty fuzzy miery spoľahlivosti v týchto prípadoch teda neodzrkadľujú chybu modelu, ale poukazujú na inherentnú nejednoznačnosť samotných vstupných údajov. Model v tomto kontexte správne signalizuje nízku úroveň istoty rozhodnutia, čím

demonštruje korektnú aplikáciu princípov fuzzy logiky. Namiesto nútenej klasifikácie nejasných prípadov model adekvátne vyjadruje neistotu v predikcii.

Analýza ďalej ukazuje, že nesprávne predikcie sa vyskytujú najmä pri prechodoch medzi susediacimi triedami (*acc* ↔ *good*, *unacc* ↔ *acc*), čo naznačuje schopnosť modelu citlivo reagovať na hraničné prípady. Vzhľadom na limitovanú diskriminačnú schopnosť dostupných atribútov je takáto neistota v rozhodovaní prirodzeným dôsledkom charakteru údajov.

Zistenia preto podporujú hypotézu, že fuzzy reliability metrika efektívne identifikuje oblasti atribútového priestoru so zvýšenou nejednoznačnosťou a poskytuje relevantnú spätnú väzbu o spoľahlivosti modelových predikcií.

4.2.2 Balance Scale dataset

4.2.2.1 Parametre a charakteristika Balance Scale

Balance Scale je založený na psychologických experimentoch hodnotenia rovnováhy váh. Obsahuje 625 príkladov, pričom každý príklad je opísaný štyrmi diskrétnymi vstupnými atribútmi a jednou cieľovou triedou určujúcou výsledok váženia.

Popis jednotlivých atribútov a ich domén hodnôt je uvedený v Tabuľka 28.

Tabuľka 28 Štruktúra vstupných a cieľových premenných v datasete Balance Scale

Názov atribútu	Popis atribútu	Doména hodnôt	Typ
Left_weight	Hmotnosť závažia na ľavej strane	1, 2, 3, 4, 5	Input
Left_distance	Vzdialenosť závažia na ľavej strane od stredu	1, 2, 3, 4, 5	Input
Right_weight	Hmotnosť závažia na pravej strane	1, 2, 3, 4, 5	Input
Right_distance	Vzdialenosť závažia na pravej strane od stredu	1, 2, 3, 4, 5	Input
Class	Výsledok váženia	L (left), B (balanced), R (right)	Target

Kódovanie hodnôt jednotlivých atribútov na diskrétne hodnoty je zhrnuté v Tabuľka 29.

Tabuľka 29 Diskrétne kódovanie hodnôt atribútov datasetu Balance Scale

Atribút	0	1	2	3	4
Left_weight	1	2	3	4	5
Left_distance	1	2	3	4	5
Right_weight	1	2	3	4	5
Right_distance	1	2	3	4	5

4.2.2.2 Porovnanie výkonnosti modelov

Výsledky experimentu na datasete Balance Scale sú zhrnuté v Tabuľke 30, kde porovnávame výkonnosť pôvodného a navrhnutého modelu vo všetkých troch režimoch hodnotenia spoľahlivosti.

Tabuľka 30 Výkonnosť modelov vo všetkých režimoch učenia v datasete Balance Scale

Model	Režim	Presnosť (%)	Priemerná spoľahlivosť (R)
Originálny model	baseline	92.2	1.1
Originálny model	retrained	76.6	1.1
Originálny model	batched-end	92.0	1.1
Navrhnutý model	baseline	92.2	1.1
Navrhnutý model	retrained	76.6	1.1
Navrhnutý model	batched-end	92.0	1.0

Získané hodnoty ukazujú, že oba modely dosahujú veľmi podobnú presnosť klasifikácie v režimoch baseline a batched-end. Aj priemerná fuzzy spoľahlivosť zostáva vo všetkých prípadoch takmer rovnaká, pričom navrhnutý model v režime batched-end vykazuje nepatrne lepšiu spoľahlivosť.

Relatívne nižšia presnosť oboch modelov v režime retrained poukazuje na zvýšenú citlivosť modelov na sekvenčné učenie bez priebežného premiešania údajov. V tomto prípade je však zachovaná stabilná úroveň fuzzy spoľahlivosti, čo naznačuje, že hoci sa presnosť znižuje, istota modelových rozhodnutí sa nemení.

Celkové výsledky preto naznačujú, že navrhnutý model dosahuje porovnateľnú výkonnosť s originálnym modelom, avšak v režime batched-end prejavuje mierne lepšie vlastnosti z hľadiska fuzzy spoľahlivosti. Dôležitým zistením je, že oba modely vykazujú vysokú stabilitu a robustnosť klasifikácie pri analýze datasetu Balance Scale, čo potvrdzuje vhodnosť navrhnutého prístupu na riešenie takéhoto typu klasifikačných úloh.

4.2.2.3 Vplyv operácie shuffle na presnosť a spoľahlivosť v režime retrained

Predložené výsledky pre dataset Balance Scale opäť potvrdili trend, ktorý bol pozorovaný aj pri datasete Car Evaluation – režim retrained vykazuje výrazný pokles presnosti v porovnaní s režimami baseline a batched-end. Nižšia presnosť v režime retrained naznačuje, že model v tomto režime je citlivejší na poradie vstupných dát, čím dochádza k zníženiu jeho schopnosti generalizovať naučené vzory. Táto situácia vzniká v dôsledku pretrénovania modelu na dátach, ktorých sekvencia nie je vhodne usporiadaná, čo negatívne ovplyvňuje schopnosť modelu správne generalizovať získané znalosti. Zavedením operácie shuffle došlo k rovnomernejšiemu rozdeleniu vzoriek počas fázy učenia, čo viedlo k citeľnému nárastu výkonnosti jednotlivých modelov.

Zmeny v presnosti a fuzzy spoľahlivosti pred a po použití operácie shuffle sú zachytené na Obrázku 11 a Obrázku 12.

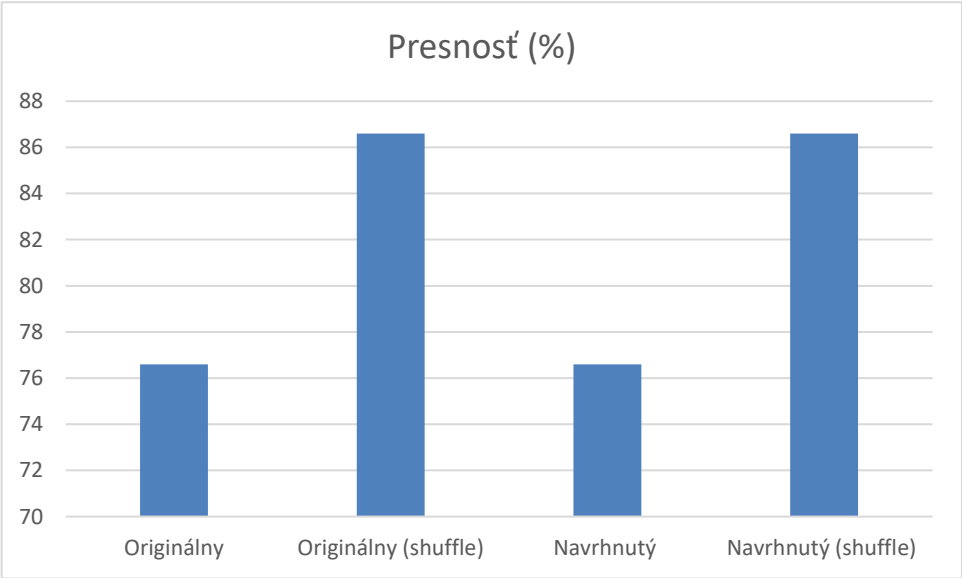

Obrázok 11 Porovnanie presnosti pôvodného a navrhnutého modelu pred a po shuffle dataset Balance Scale

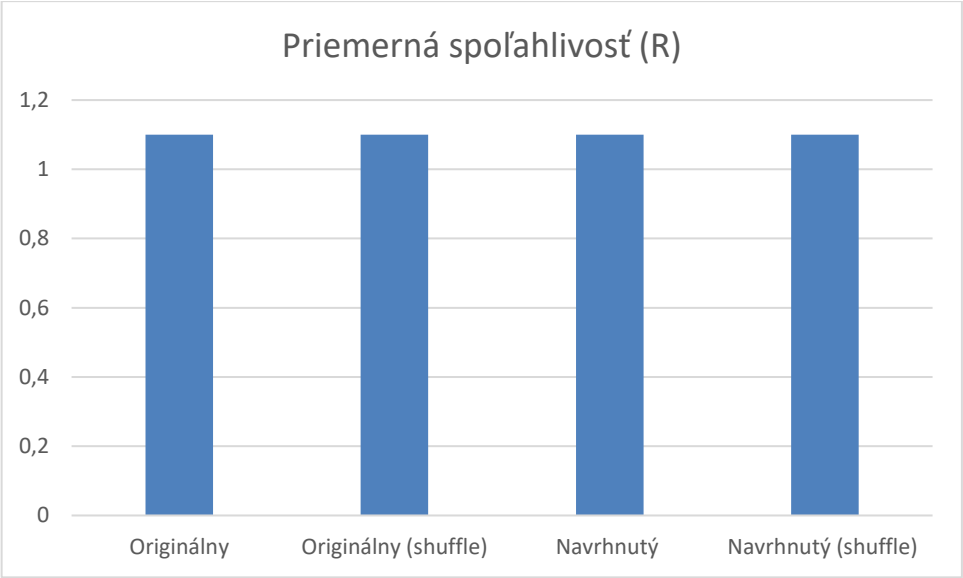

Obrázok 12 Zmena priemernej fuzzy spoľahlivosti modelov po shuffle operácii dataset Balance Scale

Z Obrázku 11 je viditeľné, že presnosť v režime retrained bez použitia operácie shuffle bola nižšia (76,6 %), pričom po aplikácii shuffle operácie sa táto presnosť zvýšila až na úroveň 86,6 %. Zároveň vidíme, že v oboch režimoch (originálny aj navrhnutý) boli namerané rovnaké hodnoty, čo naznačuje, že navrhované rozšírenie modelu neprinieslo ďalšie zvýšenie presnosti ani spoľahlivosti v tomto konkrétnom datasete.

Z Obrázku 12 možno pozorovať, že priemerná fuzzy spoľahlivosť (R) zostala v oboch režimoch (so shuffle aj bez neho) na konštantnej úrovni 1,1, čo naznačuje, že istota modelov pri rozhodovaní bola stabilná bez ohľadu na použitie operácie shuffle.

Získané výsledky môžu byť dôsledkom charakteristiky datasetu Balance Scale, ktorého atribúty sú definované jednoduchým vzťahom (násobkom hmotnosti a vzdialenosti). Práve táto vlastnosť datasetu spôsobuje, že vypočítaná vzájomná informácia (MI) pre rozhodovací proces môže byť nulová alebo veľmi nízka, a preto navrhované rozšírenia modelu nezlepšujú jeho výkon. Tento výsledok potvrdzuje, že pre datasety s jednoduchou, presne definovanou logikou nemusí aplikácia pokročilých modifikácií rozhodovacieho algoritmu priniesť dodatočné výhody.

4.2.2.4 Analýza príkladov s nízkou mierou spoľahlivosti

Pre detailnejšie pochopenie správania modelu v hraničných prípadoch sme analyzovali príklady s najnižšou fuzzy mierou spoľahlivosti v režime Navrhnutý model bez shuffle, retrained. Tabuľka 31 sumarizuje 10 príkladov, pri ktorých bola nameraná spoľahlivosť pod hranicou 10 %.

Tabuľka 31 Príklady s extrémne nízkou fuzzy spoľahlivosťou v hraničných prípadoch v datasete Balance Scale

ID	Attr1	Attr2	Attr3	Attr4	Actual	Predicted	Reliability (%)
27	1	2	1	2	B	L	0.4%
26	1	2	1	1	L	B	0.5%
2	1	1	1	2	R	B	1.0%
53	1	3	1	3	B	L	1.5%
79	1	4	1	4	B	L	2.6%
105	1	5	1	5	B	L	3.4%
253	3	1	1	3	B	L	5.8%
127	2	1	1	2	B	L	6.0%
505	5	1	1	5	B	L	7.5%
379	4	1	1	4	B	L	8.0%

Z tabuľky vyplýva, že väčšina príkladov má veľmi podobnú štruktúru vstupných údajov, najmä rovnakú hmotnosť a vzdialenosť na oboch stranách váh alebo minimálny rozdiel momentov (váha × vzdialenosť). Takéto prípady vedú k hraničným hodnotám, kde sa rozhodovacie hranice medzi triedami *Left (L)*, *Right (R)* a *Balanced (B)* stávajú neostré alebo sa prekrývajú.

Najnižšie hodnoty fuzzy spoľahlivosti sa preto objavujú tam, kde model čelí prirodzenej nejednoznačnosti — napríklad keď sú momenty na oboch stranách takmer rovnaké alebo sa líšia iba minimálne. Model v takýchto situáciách správne reflektuje nízku úroveň istoty vo svojom rozhodnutí, čím demonštruje efektívne využitie fuzzy prístupu.

Nesprávne predikcie sa navyše vyskytujú práve pri prechodoch medzi susediacimi triedami (napr. $B \leftrightarrow L$ alebo $B \leftrightarrow R$), čo potvrdzuje, že aj malá odchýlka vo vstupných hodnotách môže viesť k zmene klasifikácie. To zodpovedá psychologickému charakteru datasetu a poukazuje na obmedzenú diskriminačnú schopnosť v týchto prípadoch.

Zistenia teda podporujú záver, že fuzzy metrika spoľahlivosti úspešne identifikuje oblasti s vysokou mierou neurčitosti a poskytuje relevantnú spätnú väzbu pre ďalšiu

interpretáciu výsledkov modelu. Chovanie modelu je v tomto prípade korektné a plne v súlade s cieľom fuzzy hodnotenia neistých prípadov.

4.3 Záver

V predloženej práci bol navrhnutý a experimentálne overený fuzzy model hodnotenia spoľahlivosti údajov založený na váhovej distribúcii alternatívnych rozhodnutí. Cieľom modelu bolo kvantifikovať mieru istoty predikcie pri klasifikácii diskrétnych údajov, a tým identifikovať potenciálne hraničné alebo nejednoznačné prípady, kde nie je možné s vysokou dôverou priradiť konkrétnu triedu.

Navrhnutý model bol implementovaný ako rozšírenie tradičného rozhodovacieho procesu, pričom využíval interpoláciu pravdepodobností a váhové ohodnotenie konkurenčných tried na výpočet fuzzy miery spoľahlivosti. Experimentálne testovanie prebehlo na dvoch štandardných datasetoch: Car Evaluation a Balance Scale pričom každý z nich obsahoval špecifické výzvy z hľadiska distribúcie tried, redundancie atribútov či nerovnomerného rozloženia príkladov.

Výsledky ukázali, že navrhnutý model v režimoch baseline a batched-end dosahoval porovnateľnú alebo vyššiu klasifikačnú presnosť v porovnaní s pôvodným modelom, a zároveň poskytoval dodatočnú informáciu o spoľahlivosti predikcie. Režim retrained bez aplikácie operácie shuffle systematicky vykazoval zníženú presnosť, čo potvrdzuje dôležitosť náhodného premiešania údajov pred opakovaným učením. Po aplikácii shuffle sa výkon modelov zlepšil, najmä v datasete Balance Scale, kde model začal správne generalizovať aj v prípadoch symetricky rozdelených vstupných hodnôt.

Analýza príkladov s extrémne nízkou fuzzy spoľahlivosťou odhalila prípady, v ktorých dochádzalo ku kolízii rozhodovacích momentov – predovšetkým v situáciách, kde malá zmena jednej hodnoty mohla zmeniť výsledok klasifikácie. To poukazuje na citlivosť modelu voči nejednoznačnosti a potvrdzuje jeho schopnosť signalizovať neistotu v rozhodnutí bez nutnosti umelého zvyšovania presnosti.

Na základe výsledkov možno navrhnúť niekoľko smerov pre budúci výskum:

- Rozšírenie fuzzy modelu o možnosť identifikovať konkrétne atribúty, ktorých zmena by viedla k zvýšeniu spoľahlivosti rozhodnutia. Takáto funkcionalita by mohla slúžiť ako spätná väzba pre používateľa alebo systém na odporúčanie doplňujúcich vstupov.
- Aplikácia modelu na reálne, nevyvážené alebo čiastočne neúplné datasety, kde by fuzzy prístup mohol naplno ukázať svoju výhodu pri práci s neistotou.

- Kombinácia s inými metódami vysvetliteľného strojového učenia (XAI), napríklad na vizualizáciu rozhodovacích oblastí s vysokou mierou neistoty.

Navrhnutý fuzzy model teda predstavuje efektívny nástroj na hodnotenie spoľahlivosti klasifikácie a ponúka možnosť rozšírenia rozhodovacích systémov o dodatočnú úroveň istoty, čo je kľúčové pri nasadzovaní modelov do citlivých alebo bezpečnostne kritických oblastí.

Zoznam použitej literatúry

[UCI] **Dua, D., Graff, C.** *UCI Machine Learning Repository [online]. Irvine, CA: University of California, School of Information and Computer Science, 2019.* [Online] [Dátum:3.4 2025.] *https://archive.ics.uci.edu/ml/index.php*

[Wand1996] **Wand, Y., Wang, R.Y.** Anchoring Data Quality Dimensions in Ontological Foundations. Communications of the ACM, 39(11):86–95, 1996.

[Batini2006] **Batini, C.,** Scannapieco, M. Data Quality: Concepts, Methodologies and Techniques. Springer, 2006.

[Zadeh1965] **Zadeh, L. A.** Fuzzy Sets. Information and Control, 8(3):338–353, 1965.

[Maimon2001] **Maimon, O., Kandel, A., Last, M.** Information-theoretic fuzzy approach to data reliability and data mining. Fuzzy Sets and Systems 117, 183–194.

[Bishop2006] **Bishop, C. M.** *Pattern Recognition and Machine Learning.* Springer, 2006.

[Hastie2009] **Hastie, T., Tibshirani, R., Friedman, J.** *The Elements of Statistical Learning.* 2nd ed., Springer, 2009.

[Gelman2013] **Gelman, A**. et al. *Bayesian Data Analysis.* 3rd ed., CRC Press, 2013.

[Cover1991] **Cover, T., Thomas, J.** *Elements of Information Theory.* Wiley, 1991.

[Kohavi1996] **Kohavi, R., Wolpert, D. H.** *Bias Plus Variance Decomposition for Zero-One Loss Functions.* ICML, 1996.

Prílohy

Zoznam príloh

Príloha A Obsah DVD.....72

Príloha A | Obsah DVD

Priložené DVD obsahuje:

- Práca v elektronickej podobe (formát PDF)
- Zdrojové kódy